让资源行动可观测：AEIC 介导的多智能体大语言模型审议机制设计

Tiancheng Ma[1]

School of Computer Science
author@university.edu

摘要 多智能体语言模型系统通常优化最终聚合结果，却很少观测产生该结果的行为。当完整独立报告比短答案或模仿具有更高成本时，系统无法区分真实审议与低成本一致。本文提出 *AEIC-MD*：以假设–证据–推理–结论（AEIC）报告作为机制设计者与 LLM Agent 之间可观测接口的审议框架。求解前，每个 Agent 观察公开信用–成本规则，并从低资源报告、完整 AEIC 推理、追加验证和同伴模仿中选择行动；行动控制真实生成过程，并在结算前写入日志，从而可以直接检验追随者响应。

在 StrategyQA、MMLU-Hard 和 TruthfulQA 的 450 道配对测试题上，静态 AEIC 规则将高资源行动率从 0.46% 提高到 56.93%，多数投票准确率从 68.00% 提高到 82.22%（+14.22 个百分点；Holm 校正 McNemar $p = 1.23 \times 10^{-11}$）。仅结果奖励只将高资源行动率提高到 3.08%，且未改善准确率（67.33%，$p = 0.780$）。奖励和成本扫描呈现预期单调响应；受控信息环境、额外 Seed、信号与历史消融以及 3–5 Agent 面板限定了稳健性。留出 GLM 后端未复现行动或准确率增益（69.33% 对 70.67%，$p = 0.791$），表明合同必须针对后端校准。八组预注册实验共包含 5,850 条经核验的问题级记录。结果支持有边界的结论：针对可验证报告结构的公开规则能够改变追随者资源行动并改善集体决策，但合同语义不会自动跨模型家族迁移。

Keywords: 多智能体大语言模型 · 机制设计 · 结构化推理 · 群体审议 · 追随者响应

1 引言

LLM Agent 能够辩论、批评、投票并综合彼此输出，但聚合结果的价值取决于产生它的行为。短答案、独立推理报告、追加验证和模仿同伴具有不同成本与信息价值。多数评测只观察最终答案，使系统无法区分真实审议与廉价一致。

这首先是机制设计问题，其次才是聚合问题。设计者必须在 Agent 行动前宣布何种行为获得信用，Agent 再决定预期信用是否值得资源投入。对既有回答做回溯加权不能建立追随者响应，因为生成策略未观察该规则；改变拓扑也只能控制信息流向，不能决定 Agent 是否生产可独立检查的信息。

本文提出 **AEIC-MD**。报告包含 Assumption、Evidence、Inference 和 Conclusion 四个可解析字段。求解前，追随者观察包含信用规则、行动成本、信息策略和验证预算的公开合同，并从 Low、AEIC、Verify 和 Imitate 中选择。行动选择真实生成路径；报告、资源、信用、成本和信誉更新均被记录。这把“先承诺、后响应”的 Stackelberg 直觉转化为可证伪实验。

确认性实验在三个任务域的 450 道留出题上配对比较三种规则。Static AEIC 将高资源行动率从 0.46% 提高到 56.93%，准确率从 68.00% 提高到 82.22%；Outcome Only 仅提高到 3.08%，准确率无显著变化。因此结果不是一般奖励语言改善回答，而是局部可读过程规则改变行动策略与集体结果。

本文还用奖励–成本扫描、四类信息环境、信号与历史消融、额外 Seed、不同面板规模和留出 GLM 后端检验解释。GLM 未响应同一合同，这一负结果排除普适性强主张，并将后端合同校准确定为开放问题。

本文贡献为：

1. 可执行 Leader–Follower 协议：规则先于行动，行动控制真实资源路径；
2. 配对证据表明 AEIC 过程规则相对仅结果奖励能够改变资源行动并改善集体准确率；
3. 完整冻结的八组评测，覆盖剂量响应、信息控制、消融、稳健性和明确的不迁移边界。

2 相关工作

多智能体审议。 Self-consistency 聚合采样推理路径 [13]；多智能体辩论在聚合前让模型实例彼此可见 [5]；ChatEval 与 AgentVerse 组织专业 Agent 或评估者 [1,3]。近期研究还揭示同质面板中的从众、谄媚和有效分歧损失 [9,12]。AEIC-MD 关注更早的决策：Agent 是否选择承担可独立检查报告的成本。

作为接口的结构化推理。 Chain-of-Thought、Tree-of-Thoughts 和 ReAct 组织单模型计算 [15,16,17]。AEIC 统一观测报告完整性、最终立场和资源行动。它既是生成协议，也是可缔约报告空间；本文不假设格式保证真实性。

语言模型机制设计。 LLM 的委托–代理和合同视角区分设计者承诺与 Agent 响应 [10,11]；Stackelberg 激励也用于分布式学习和众包 [6,7,14]。AEIC-MD 直接执行“规则先呈现、行动先声明、路径后执行”的顺序，区别于对未见规则时生成的回答做离线评分。

通信结构与生产激励。 拓扑决定报告如何流动 [8,2]，却不能保证报告包含独立工作。本文将信息结构作为受控环境和未来设计层；确认性实验固定信息流，仅改变公开规则。

3 作为可观测报告空间的 AEIC

对问题 x，Agent i 提交

$$r_i = (A_i, E_i, I_i, C_i), \tag{1}$$

其中 A_i 给出操作性假设，E_i 列出具体证据，I_i 连接证据与答案，C_i 包含明确立场。严格四字段 JSON 由此区分结构完整性、向后续 Agent 暴露的证据和最终答案。

AEIC 并非正确性证明。完整报告可能自洽但错误，Agent 也可能在填满字段时模仿同伴。定义完整度

$$q_{\text{comp}}(r) = \frac{1}{4} \sum_{z \in \{A,E,I,C\}} \mathbf{1}[z\text{非空}], \tag{2}$$

并令 $q_C(r)$ 表示 C 是否给出合法任务立场。静态规则仅使用这些过程信号，不向行动选择提示提供真实答案。

区分*可观测过程*与*事实真值*是有意设计。仅结果信用要求环境在任务后知道正确性，而过程信用可以从报告本身提前宣布并检查。二者比较用于判断延迟结果奖励是否与绑定到可读生产过程的规则具有相同行为效应。

4 AEIC 介导的 Leader–Follower 机制

4.1 时序与行动空间

Leader 在生成前承诺合同 m，追随者观察后选择

$$a_i \in \mathcal{A} = \{\textsc{Low}, \text{AEIC}, \textsc{Verify}, \textsc{Imitate}\}. \tag{3}$$

四种行动分别触发低成本短报告、独立完整 AEIC 推理、追加验证调用和同伴信息综合。行动会选择不同 Prompt、Token 上限，并在分层执行器中选择不同模型资源。

合同包含信用规则 g_m、行动成本 $c_m(a)$、信息策略和验证预算。追随者的净效用写为

$$U_i(a_i; m, h_i) = \mathbb{E}[g_m(r_i, y, h_i) \mid a_i, m, h_i] - c_m(a_i), \tag{4}$$

其中 h_i 为可见历史，y 仅在需要结果验证时对结算环境可用。本文不声称模型精确计算该式；检验对象是奖励或成本变化时行动分布是否改变。

4.2 比较规则

确认性实验固定问题、Seed、面板、轮数和信息策略，比较 No Mechanism、Outcome Only 和 Static AEIC。前者不提供显式信用；第二种仅为正确最终立场结算；第三种按 AEIC 完整性和合法结论结算且不读取答案键。令 $H(a) = \mathbf{1}[a \in \{\text{AEIC}, \textsc{Verify}\}]$。主要估计量分别是 $\mathbb{E}[H]$ 和问题级多数票正确率的配对变化，Token 作为资源结果单独报告。

4.3 结算与纵向状态

$$\rho_i^t = \delta \rho_i^{t-1} + g_m(r_i^t, y, h_i^t) - c_m(a_i^t), \qquad \delta = 0.9. \tag{5}$$

静态规则不按信誉自适应系数，但保留完整状态以支持历史消融与未来合同。失败尝试回滚，重试和修复仍保留在 Trace 中。

5 实验协议与审计轨迹

同步面板。 每道题由 5 个 Agent 进行 3 轮同步处理。第 t 轮只能观察策略允许的第 $t-1$ 轮报告，同轮 Agent 彼此不可见。确认性实验使用独立信息条件；受控实验分别暴露新增证据、无证据多数立场、带复制压力的完整报告或立场相反证据。

图 2给出实现顺序：控制器先承诺，追随者声明行动，执行器运行对应路径，结算后才生成后续历史。失败进入可审计重试或回滚分支。

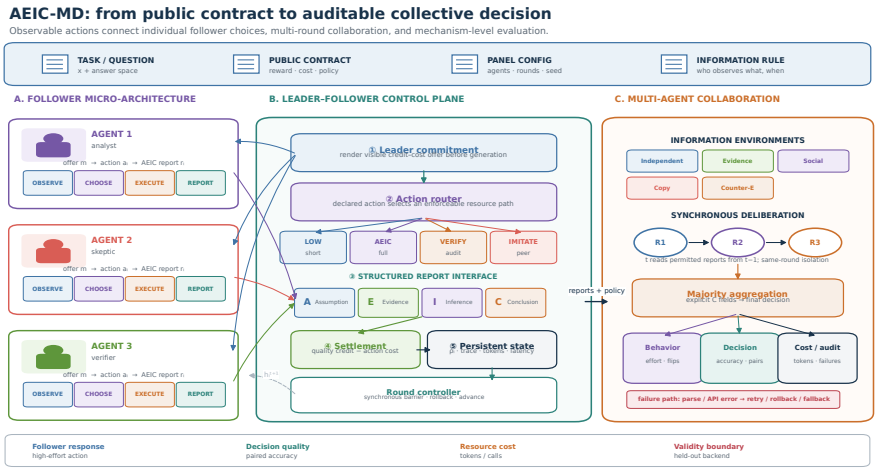


图 1. AEIC-MD 架构。合同先于资源行动选择，控制器在执行后结算并记录状态。

先选择后执行。 Agent 先接收合同、信誉、允许信息和问题并返回单一行动；第二次调用执行行动，VERIFY 增加审计与修订调用。仅解析失败时允许格式修复，且不得改变原结论或添加事实。

配对与聚合。 同一道题的机制共享问题级 Seed。最终决策取第三轮 C 字段多数票。高资源行动预先定义为 AEIC 或 VERIFY。二元结果使用精确 McNemar 检验，连续结果使用配对秩检验，并在注册比较族内 Holm 校正。

冻结溯源。 版本化 Schema 要求记录合同、行动、报告、可见同伴、奖励、成本、信誉、原始响应、Trace、延迟和 Token。八组实验共 5,850 条问题级记录，均通过矩阵、路由和 Schema 校验，以 SHA-256 冻结并从标准 JSONL 独立复算。

6 识别与结论边界

AEIC-MD 使用 Stackelberg 时序而不声称闭式均衡：设计者承诺 m，追随者再响应。经验对象是黑盒策略诱导的行动分布 $\pi(a \mid x, m, h)$。

追随者响应。 在配对任务上改变 m 并固定问题、Seed、面板、轮数和信息策略，可识别公开规则对已实现模型策略的意向处理效应。正的高资源行动差异证明规则响应，但不证明任意 Agent 效用最大化或激励相容。

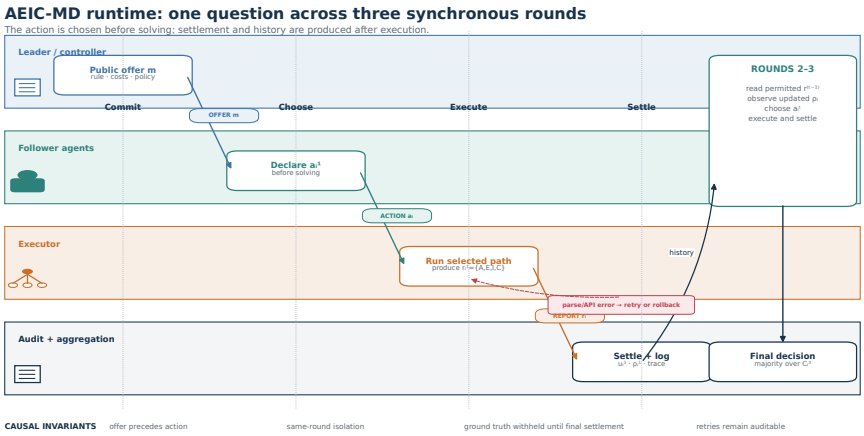


图 2. 单题运行时序。四条泳道区分承诺、选择、强制执行和结算。

仅结果控制。 Static AEIC 与 Outcome Only 区分过程可观测性和一般奖励语言。它支持局部可检查接口是有效组成，但不隔离四个 AEIC 字段的独立贡献；信号消融只是描述性边界。

剂量响应。 式 (4)预测奖励提高时高资源行动弱增加、成本提高时弱降低。本文检验方向含义而不拟合结构效用模型；冻结高低点和开发中心点支持单调性，而非第二个确认性效应。

外部有效性。 Prompt 介导的成本和信用具有后端语义，一个模型上的合同未必迁移到另一模型。因此本文将留出后端作为范围检验，不主张一般均衡、Leader 全局最优、货币激励相容或拓扑无关有效性。

7 实验

7.1 实验设置

我们从 StrategyQA、MMLU-Hard 和 TruthfulQA 各使用 150 道留出题。每个条件包含 5 个 Agent 和 3 轮同步审议，主后端为 DeepSeek-V3 [4]。确认性实验包含 $450 \times 3 = 1{,}350$ 条问题–条件记录和 20,250 个 Agent-round。三种规则的问题、Seed、面板、轮数和聚合方式均配对，只有公开合同改变。最终决策取第三轮明确结论的多数票。

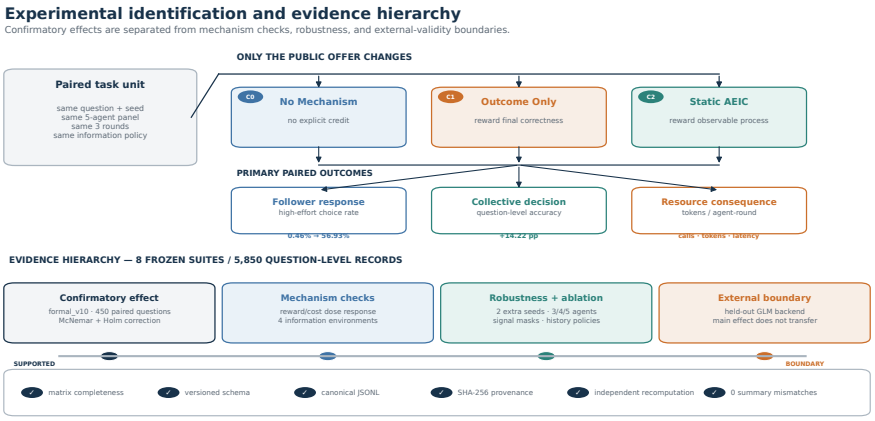


图 3. 实验识别与证据层级。配对条件隔离公开规则，八组冻结实验覆盖确认、机制检验、稳健性、消融与不迁移边界。

表 1. 450 道问题上的确认性配对检验。高资源行动在每种规则的 6,750 个 Agent-round 上测量。

规则	高资源行动	准确率	Token/Agent-round
No Mechanism	0.46%	68.00%	663.3
Outcome Only	3.08%	67.33%	689.2
Static AEIC	**56.93%**	**82.22%**	808.8

主要结果是高资源行动率（AEIC 与 VERIFY 占比）和问题级准确率；同时报告每 Agent-round Token、采集完整性和分域效应。配对二元结果采用精确 McNemar 检验，并在注册比较族内进行 Holm 校正。图 3概括识别逻辑和证据层级。

7.2 确认性追随者响应检验

Static AEIC 同时改变追随者行为和集体决策（表 1；图 4）。高资源行动率增加 56.47 个百分点；准确率增加 14.22 个百分点，相对 No Mechanism 有 78 道题由错变对、14 道由对变错（Holm 校正 McNemar $p = 1.23 \times 10^{-11}$）。每 Agent-round 额外 145.5 Token 与更完整工作的资源成本一致。

Outcome Only 只将高资源行动率提高 2.62 个百分点，准确率变化 −0.67 个百分点（27 道纠正、24 道受损；$p = 0.780$）。因此主效应不能概括

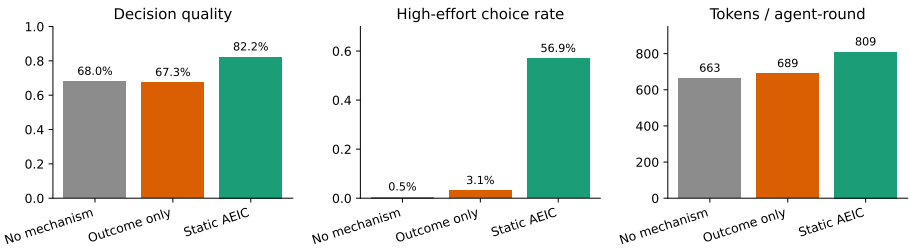


图 4. 正式配对比较。Static AEIC 改变资源行动并改善最终准确率，仅结果奖励没有改善准确率。

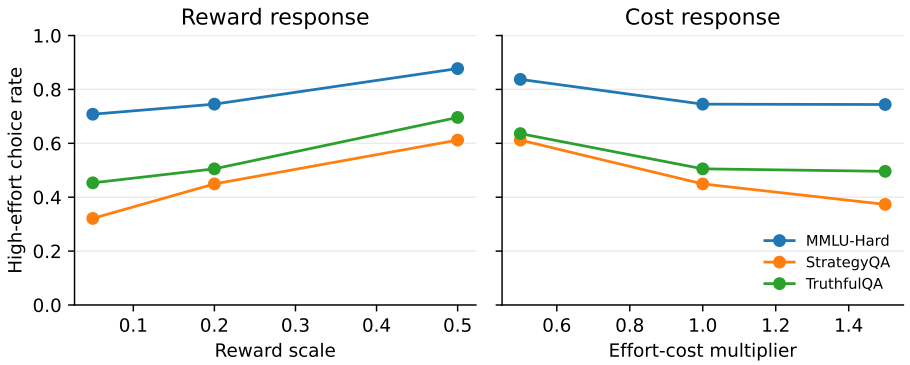


图 5. 对公开合同的方向性响应：奖励提高时资源行动上升，行动成本提高时下降。

为“告诉模型存在奖励”；区别在于规则是否提供追随者可通过生产过程满足的局部标准。

增益存在分域异质性：StrategyQA 为 +4.0、MMLU-Hard 为 +20.0、TruthfulQA 为 +18.7 个百分点；对应高资源行动增益为 43.5、73.7 和 52.2 个百分点。因此总体效应不是任务无关常数。

7.3 奖励–成本响应

在每个任务域，奖励从 0.05 增至 0.2 和 0.5 时高资源行动单调不减；成本倍率从 0.5 增至 1.0 和 1.5 时单调不增（图 5）。冻结极值汇总中，高资源行动随奖励由 49.42% 升至 72.84%，随成本由 69.51% 降至 53.78%。中点来自同域开发观察，因此该实验是方向性机制检查而非第二个确认性效应。

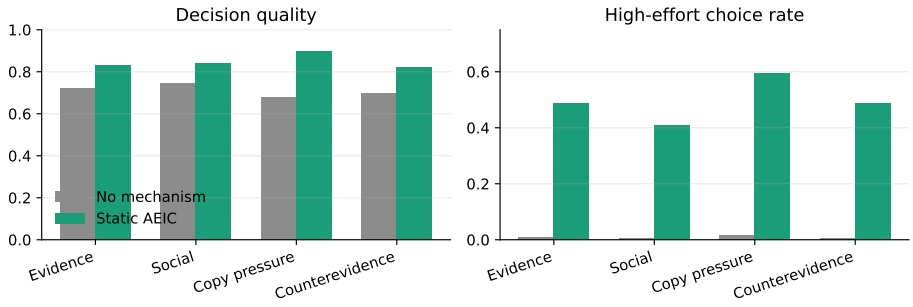


图 6. 受控信息环境中的高资源行动。Static AEIC 在四种设置中均改变行为。

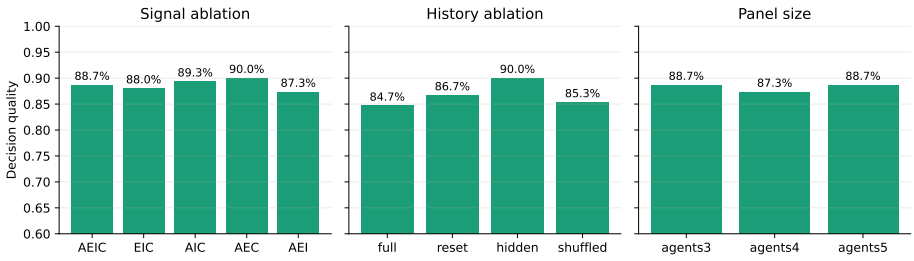


图 7. 信号、历史、Seed 与面板规模稳健性。组件变体是描述性边界。

7.4 受控信息环境

我们只改变第一轮后可见的同伴信息：新增证据、无证据多数立场、带复制压力的完整报告或立场相反证据。四类环境中，Static AEIC 将汇总高资源行动率从 0.86% 提高到 49.41%；各条件下为 40.89%–59.33%，无机制时为 0.44%–1.47%（图 6）。这说明接口在不同信息结构下仍有行为作用，但不证明每种信息干预都改善准确率或消除模仿。

7.5 稳健性、消融与外部有效性

两个额外 Seed 复现主方向：Static AEIC 准确率 85.67%，无机制 71.00%（+14.67 个百分点；Holm 校正 $p = 2.40 \times 10^{-9}$）。3、4、5 Agent 条件下准确率为 87.33%–88.67%。信号遮蔽和历史策略变体只限定当前实现，并不证明每个字段独立必要；移除字段会改变后端对整个合同的理解，因此属于干预消融而非模块化证明。

留出 GLM 后端给出最强边界。Static AEIC 仅将高资源行动率从 0.58% 变为 0.93%（$p = 0.134$），准确率为 69.33%，而无机制为 70.67%（Holm 校正 $p = 0.791$）。相同文字和数值并不跨模型定义同一有效合同。AEIC-MD 是针对已测试主后端得到实验验证的机制，而不是普适校准的激励语言。

7.6 完整性与可复现性

八组冻结实验的 5,850 条预期问题级记录全部存在；各组通过 Schema 和路由验证，独立复算包与摘要无差异。确认性数据中 API 终止失败为零、成本日志完整；少量解析失败经重试且保留在尝试日志。Manifest 保存标准哈希，防止分析记录被静默替换。

8 讨论

机制而非格式本身。 AEIC 的价值在于产生可缔约观测量，而非四个标签保证良好推理。Static AEIC 在规则与观测量绑定时改变行为，Outcome Only 说明一般奖励语言不足；但信号消融也不支持每个字段独立不可缺少的主张。

负迁移的重要性。 GLM 结果表明，由 Prompt 介导的成本和信用通过后端特定策略解释，合同数值尚非通用货币。下一步应先在开发集估计各后端响应面，再在留出任务上测试固定合同；混合模型面板也应在解决校准后评估。

与拓扑和审议的关系。 生产激励决定是否产生信息性工作，通信拓扑决定谁能以何种成本观察这些工作。受控信息实验开始连接二者，却不把拓扑作为主因果变量。未来可在校准报告机制上优化信息流。

局限性。 主效应仅在一个主后端、三个二元答案 QA 域、一个 Prompt 行动菜单和多数聚合下建立。行动是 LLM 在指令下产生的行为，不代表类人偏好；信用是记账量而非货币；过程完整不等于事实验证。确认性实验检验固定静态规则，而非自适应 Stackelberg 最优性或一般均衡。更多调用和更长报告也带来真实计算成本。

更广泛含义。 该框架适用于中间工作可局部检查、执行器能够强制行动差异的场景，不应从结构完整但不可验证的报告制造虚假信心。因此记录合同、行动、执行路径和结算是贡献的一部分，而不只是工程日志。

9 结论

AEIC-MD 将结构化报告转化为 Leader–Follower 实验的可观测接口。公开 Static AEIC 规则显著改变主后端的资源行动并改善集体准确率，仅结果奖励则没有。剂量响应、信息控制、稳健性实验和冻结溯源支持这一有边界的解释。留出后端失败同样重要：有效合同必须针对解释它的模型策略校准。由此得到的研究方向不是不断增加拓扑复杂度，而是依次实现可观测资源行动、经校准激励，并在此基础上优化自适应信息流。

参考文献

1. Chan, C.M., Chen, W., Su, Y., Yu, J., Xue, W., Zhang, S., Fu, J., Liu, Z.: ChatEval: Towards better LLM-based evaluators through multi-agent debate. In: Proceedings of the 12th International Conference on Learning Representations (ICLR) (2024), https://arxiv.org/abs/2308.07201
2. Chen, J.C.Y., Saha, S., Bansal, M.: ReConcile: Round-table conference improves reasoning via consensus among diverse LLMs. In: Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL). pp. 3539–3561 (2024). https://doi.org/10.18653/v1/2024.acl-long.193, https://arxiv.org/abs/2309.13007
3. Chen, W., Su, Y., Zuo, J., Yang, C., Yuan, C., Chan, C.M., Yu, H., Lu, Y., Hung, Y.H., Qian, C., Qin, Y., Cong, X., Xie, R., Liu, Z., Sun, M., Zhou, J.: AgentVerse: Facilitating multi-agent collaboration and exploring emergent behaviors. In: Proceedings of the 12th International Conference on Learning Representations (ICLR) (2024), https://arxiv.org/abs/2308.10848
4. DeepSeek-AI: DeepSeek-V3 technical report. CoRR **abs/2412.19437** (2024). https://doi.org/10.48550/arXiv.2412.19437, https://arxiv.org/abs/2412.19437
5. Du, Y., Li, S., Torralba, A., Tenenbaum, J.B., Mordatch, I.: Improving factuality and reasoning in language models through multiagent debate. In: Proceedings of the 41st International Conference on Machine Learning (ICML) (2024), https://arxiv.org/abs/2305.14325
6. Fu, Y., Dong, M., Zhou, L., Li, C., Yu, F.R.: A distributed incentive mechanism to balance demand and communication overhead for multiple federated learning tasks in IoV. IEEE Internet of Things Journal **11**(4), 5997–6013 (2024)

7. Guo, W., Wang, Y., Jiang, P.: Incentive mechanism design for federated learning with Stackelberg game perspective in the industrial scenario. Computers & Industrial Engineering **186**, 109741 (2023)
8. Hong, S., Zhuge, M., Chen, J., Zheng, X., Cheng, Y., Zhang, C., Wang, J., Wang, Z., Yau, S.K.S., Lin, Z., Zhou, L., Ran, C., Xiao, L., Wu, C., Schmidhuber, J.: MetaGPT: Meta programming for a multi-agent collaborative framework. In: Proceedings of the 12th International Conference on Learning Representations (ICLR) (2024), https://arxiv.org/abs/2308.00352
9. Pitre, P., Ramakrishnan, N., Wang, X.: CONSENSAGENT: Towards efficient and effective consensus in multi-agent LLM interactions through sycophancy mitigation. In: Findings of the Association for Computational Linguistics: ACL 2025 (2025). https://doi.org/10.18653/v1/2025.findings-acl.1141
10. Rauba, P., Cepenas, S., van der Schaar, M.: Multi-agent systems should be treated as principal-agent problems. CoRR **abs/2601.23211** (2026). https://doi.org/10.48550/arXiv.2601.23211, https://arxiv.org/abs/2601.23211
11. Saig, E., Einav, O., Talgam-Cohen, I.: Incentivizing quality text generation via statistical contracts. In: Advances in Neural Information Processing Systems 37 (NeurIPS) (2024), https://arxiv.org/abs/2406.11118
12. Swamy, S., et al.: Peacemaker or troublemaker? Sycophancy in multi-agent debate. arXiv preprint (2025)
13. Wang, X., Wei, J., Schuurmans, D., Le, Q.V., Chi, E.H., Narang, S., Chowdhery, A., Zhou, D.: Self-consistency improves chain of thought reasoning in language models. In: Proceedings of the 11th International Conference on Learning Representations (ICLR) (2023), https://arxiv.org/abs/2203.11171
14. Wang, Y., Zhou, Y., Huang, P.Q.: A novel incentive mechanism for federated learning over wireless communications. IEEE Transactions on Artificial Intelligence **5**(11), 5549–5563 (2024)
15. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E.H., Le, Q.V., Zhou, D.: Chain-of-thought prompting elicits reasoning in large language models. Advances in Neural Information Processing Systems **35** (2022)
16. Yao, S., Yu, D., Zhao, J., Shafran, I., Griffiths, T., Cao, Y., Narasimhan, K.: Tree of thoughts: Deliberate problem solving with large language models. Advances in Neural Information Processing Systems **36** (2024)
17. Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., Cao, Y.: React: Synergizing reasoning and acting in language models. International Conference on Learning Representations (2023)