Adaptive Topology Routing for Game-Theoretic Multi-Agent LLM Consensus via AEIC Decomposition

Tiancheng Ma[1]

School of Computer Science
author@university.edu

摘要 多智能体大语言模型（LLM）系统通过输出聚合实现集体推理，然而现有的共识机制缺乏正式的激励保证，且将通信拓扑视为固定的设计选择。我们提出了一个结合三项创新的框架：(1) AEIC（假设-证据-推论-结论）分解，一种结构化推理协议，能够跨不同通信拓扑实现可靠的结论提取和一致的多数投票；(2) Stackelberg 博弈激励机制，包含 21 个可学习参数（17 个基础参数 + 4 个动态调节参数），通过双层差分进化和交叉验证评估进行优化，可证明实现 ϵ-激励相容；(3) 自适应神经拓扑路由器，它利用从 AEIC 结构化输出中提取的特征，为每个问题从五种通信拓扑中选择最优拓扑。在三个基准测试（5 个智能体在所有 5 种拓扑上评估了 633 个问题）中，我们的路由器实现了 87.6% 的共识准确率——比最佳固定拓扑（星型，在同一评估集上为 83.1%）高出 +4.5 个百分点，弥合了与预言机上限（92.9%）之间 46.5% 的差距。一个关键发现是，AEIC 质量信号（IC、EC、EQ、EV）衡量的是推理连贯性而非答案正确性：在三种拓扑中，AEIC 加权投票与多数投票没有显著差异（McNemar p>0.10），在辩论拓扑（debate）上略差（p=0.027），仅在层级拓扑（hierarchical）上显著更好（p=0.001）。结构化输出消融实验表明，从明确的结论（Conclusion）字段中提取立场的多数投票准确率为 76.9%，而从非结构化的推论（Inference）文本中提取仅为 48.9%（+28.0 个百分点），这证实了 AEIC 的主要价值在于为智能体输出强加可解析的结构，而非质量衡量。该框架支持三层 Stackelberg 进化：静态优化发现了反奉承原则（在信息共享拓扑上 EV 权重接近零）；在线反馈在轮次间提供实时质量评估（在知识密集型的辩论中 +6.7 个百分点）；动态奉承调节监控集体立场动态（分析了 256 次转换），检测奉承趋同和死锁，然后应用差异化参数调整和提示词干预——选择性地提高知识密集型任务的准确率（在 MMLU-Hard 上 +8 个百分点，n=50），同时避免了在其他数据集上统一应用质量反馈所导致的性能下降。

Keywords: 多智能体共识 · Stackelberg 博弈 · 拓扑路由 · 大语言模型 · 激励相容

1 引言

由大语言模型（LLM）驱动的多智能体系统通过集体审议，在复杂推理任务中展现出巨大潜力 [11,24]。通过部署多个 LLM 实例独立分析问题并聚合它们的输出，这些系统在常识推理、数学问题求解和事实问答等基准测试中能够超越单智能体的性能 [26]。

然而，多智能体 LLM 协作背后存在两个基本矛盾。首先，*系统应该如何将多样化的智能体输出聚合为可靠的共识？*当前的方法——如多数投票 [26,33] 和多轮辩论 [8,6]——缺乏正式的激励保证。智能体没有被正式激励去努力产生高质量的推理，从而造成了一种*道德风险*，即下游智能体可能会奉承地采纳上游的结论 [18,2]。

其次，*智能体应该如何通信？*通信拓扑——智能体是独立推理（平行，parallel）、观察前序节点（顺序，sequential）、通过中心节点聚合（星型，star）、迭代交流（辩论，debate）还是在分组中进行层级操作（层级，hierarchical）——从根本上影响着个体推理的质量和集体判断的可靠性。然而，现有工作将拓扑视为固定的架构选择，而不是根据问题特征进行自适应决策。

我们通过一个结合博弈论共识和自适应拓扑选择的统一框架来解决这两个问题。我们的贡献如下：

1. **作为结构化推理协议的 AEIC 分解。**我们将每个智能体的推理分解为四个可解析的部分——假设（A）、证据（E）、推论（I）和结论（C）——从而实现跨所有五种通信拓扑的可靠结论提取和一致的多数投票。该分解额外产生了质量信号（IC、EC、EQ、EV），作为 Stackelberg 机制设计的形式化接口，尽管实验表明，在同质 LLM 后端下这些信号的判别能力有限（第 3 节）。
2. **具有三层进化的 Stackelberg 激励机制。**我们将共识制定为一个 Stackelberg 博弈，包含 21 个可学习参数（17 个基础参数 + 4 个动态调节参数），通过双层差分进化进行优化。该机制可证明实现 ϵ-激励相容，并跨三个层次进化：(a) 静态优化发现了可解释的参数配置文件，包括抑制跨智能体共识信号的反奉承效应；(b) 在线反馈在轮次之间注入质量评估，以实时塑造行为；(c) 动态奉承调节监控集体立场动态，并应用自适

应干预（参数调整和差异化提示词模板）来纠正奉承或死锁的群体行为（第 4 节）。

3. **使用神经评分器的自适应拓扑路由。**我们引入了一个神经拓扑路由器，它利用从 AEIC 结构化输出中提取的 42 维特征，为每个问题从五种通信拓扑中进行选择。借助特定数据集的评分头，该路由器实现了 87.6% 的准确率——弥合了最佳固定拓扑（83.1%）与预言机上限（92.9%）之间 46.5% 的差距（第 5 节）。

一个核心发现是，AEIC 质量信号衡量的是*推理连贯性*而非*答案正确性*：在 5 种拓扑中有 4 种，多数投票的表现优于 AEIC 加权聚合。结构化输出消融实验量化了 AEIC 的主要价值：从明确的结论（Conclusion）字段提取立场的多数投票准确率，比从非结构化推论（Inference）文本中提取高出 +28.0 个百分点，证实了结构化分解——而非质量衡量——是实现可靠的跨拓扑共识和自适应路由的关键赋能因素（第 7 节）。

2 相关工作

多智能体大语言模型共识。 对多个大语言模型（LLM）输出的聚合研究已经过几种范式的探索。自洽性（Self-consistency） [26] 对多条推理路径进行采样，并选择频率最高的答案。多智能体辩论（Multi-agent debate） [8,6] 将此扩展为多个模型实例之间的迭代讨论。ChatEval [3] 将此应用于评估任务。Zhao 等人 [33] 基于社会选择理论提出了基数投票机制。Li 等人 [14] 引入了动态权重。

这些系统中的一个关键故障模式是*阿谀奉承*（*sycophancy*）——智能体在没有进行真正推理的情况下采纳多数派立场。Bertalanič 和 Fortuna [2] 提供了迄今为止最全面的实证描述，记录了同构多智能体辩论（n=10）中的三种故障路径：谄媚的从众行为（高达 85.5

Pitre 等人 [18] 通过 ConsensAgent 解决了阿谀奉承问题，该机制根据智能体交互动态微调提示以减轻羊群效应。ConsensAgent 在单一辩论拓扑内的提示层面上运行。我们的动态调节有根本的不同：我们不为单个智能体优化提示，而是监控跨轮次的*集体行为动态*（立场变化率、多数比率、收敛速度），并针对检测到的特定病理特征（阿谀奉承与僵局）应用差异化干预——参数调整和提示修改。Swamy 等人 [23] 为多智能体辩论中的阿谀奉承提供了正式指标；他们关于阿谀奉承水平在不同智能体角色中存在显著差

异的发现，为我们基于立场变化的检测提供了依据。最近，Kumarappan 等人 [13] 证明，多智能体的阿谀奉承是结构性的（存在于基础模型中，而不仅仅是基于人类反馈的强化学习（RLHF）工件），缓解措施应该在“管道层面针对结构化异议”进行——这正是我们的斯塔克尔伯格动态调节通过行为状态检测和自适应 EV 权重抑制所实现的。

结构化推理分解。 思维链（Chain-of-Thought）提示 [28] 引发逐步推理，思维树（Tree-of-Thoughts） [30] 将此扩展到推理路径的结构化探索。ReAct [31] 交错进行推理与行动。这些方法对推理进行分解以提高个体答案的质量。我们的 AEIC 分解服务于不同的目的：它将智能体的输出结构化为四个可解析的字段（假设、证据、推论、结论），以实现跨智能体的操作——从明确的结论（Conclusion）字段进行可靠的立场提取（比非结构化提取高出 28 个百分点）、用于自适应路由的跨拓扑投票模式比较，以及用于动态调节机制的群体级行为动态监控（见第 4.6 节）。该分解并非旨在改进每个智能体的推理；其设计目的是使集体行为具有可观察性和可调节性。

多智能体系统中的通信拓扑。 通信结构对多智能体性能的影响已在多种语境中进行了探讨。Chen 等人 [5] 使用了集中式评估器（星型拓扑）。顺序架构出现在智能体链（chain-of-agents）设计中 [12]。Du 等人 [8] 研究了辩论拓扑（完全图）。Chen 等人 [4] 在不同的大语言模型中引入了带有置信度加权投票的圆桌会议。最近，RUMAD [25] 应用强化学习在单一拓扑类型内自适应地控制辩论轮次和智能体选择。我们的方法在三个方面有所不同：我们在五种根本不同的通信结构（并行、顺序、星型、辩论、分层）中进行选择，使用可解释的投票模式特征而不是不透明的 RL 策略，并将我们的机制建立在博弈论的激励兼容性保证上。

多智能体系统中的内存。 近期的几项工作研究了智能体内存在如何影响多智能体动态。EquiMem [17] 将多智能体辩论中的共享内存公式化为一种零信任内存博弈，其中均衡状态校准了最佳的内存信任度——这与我们的博弈论方法类似，但侧重于内存完整性而非共识激励。Liu 等人 [16] 证明了一种矛盾的“内存诅咒”，即在基于大语言模型的社会困境中，扩大回忆能力会降低合作意图（在 28 个模型-博弈配置中有 18 个出现此情况），这表明更多的历史信息并不能提高集体决策质量。这补充了我们的发现（第 7 节），即源自 AEIC 结构的质量信号无法区分正确与误导性的知识：这两个结果都表明，当智能体共享同一个底层大语言模型时，更丰富的个人信息——无论是

历史内存还是质量得分——都不一定会改善共识。我们的动态调节机制（第 4.6 节）通过对可观察的集体行为进行操作，而不是根据每个智能体的质量或内存内容进行操作，从而解决了这个问题，这使得它对信号限制和内存质量变化都具有鲁棒性。

博弈论与大语言模型。 Sun 等人 [22] 提供了大语言模型应用的博弈论分类体系。Yi 等人 [32] 将多智能体辩论建模为具有纳什均衡的贝叶斯博弈。Rauba 等人 [19] 主张对大语言模型系统进行委托-代理（principal-agent）建模。Liu 等人 [15] 使用大语言模型进行自动机制设计。最近，Meng 等人 [17] 将多智能体辩论中的共享内存构建为一个零信任内存博弈，在该博弈中，均衡会校准最佳的内存信任度，而不假设智能体是诚实的；Anand 等人 [1] 将大语言模型智能体协议定为一个拜占庭共识博弈，证明了受提示引导的智能体在经典理论保证收敛的地方无法达成一致。我们的斯塔克尔伯格（Stackelberg）公式与同时移动均衡和拜占庭共识方法不同，它将机制设计者建模为一个领导者，他在智能体行动之前*承诺*采用某种聚合规则——这非常适合于旨在通过可信的承诺来塑造追随者行为的机制设计，并且与智能体诚实假设或容错保证无关。

分布式系统中的斯塔克尔伯格博弈。 斯塔克尔伯格激励机制在联邦学习（federated learning）[9,10] 和众包（crowdsourcing）[27] 中已建立。Saig 等人 [20] 应用契约理论（contract theory）来激励大语言模型生成高质量的文本。Xu 等人 [29] 将斯塔克尔伯格博弈应用于多智能体合同修订。据我们所知，先前没有任何工作将斯塔克尔伯格机制设计应用于带有自适应拓扑路由的多智能体大语言模型共识。

与最相关工作的定位。 表 1 将我们的框架与四个最相关的方法进行了对比。

3 AEIC 分解与质量信号

我们引入了 AEIC 分解，这是一种结构化推理协议，可在不同通信拓扑结构中实现可靠的结论提取。从 AEIC 组件导出的质量信号同时用作斯塔克尔伯格机制设计的形式化接口（第 4 节）。

表 1. 与最相关工作的比较。

	正式激励	拓扑选择	阿谀奉承解决方案	结构化输出	行为规范
标准辩论（Standard Debate） [8]	—	—	—	—	—
ConsensAgent [18]	—	—	提示层级	—	—
RUMAD [25]	—	✓†	—	—	—
Bertalanič 等人 [2]	—	—	仅限分析	—	—
本项研究	✓‡	✓	✓	✓	✓

† 仅限拓扑内部（改变辩论轮次/参与度）。‡ 斯塔克尔伯格 ϵ-激励兼容性（定理 2）。

3.1 结构化推理分解

给定一个问题 x，每个智能体 $i \in \{1, \ldots, n\}$ 生成一个结构化响应，将其分解为四个组件：

- **假设 (A)**：智能体采纳的前提或假说。
- **证据 (E)**：支持其分析的事实主张列表：$E_i = \{e_{i,1}, \ldots, e_{i,k_i}\}$。
- **推理 (I)**：将证据与结论连接起来的推理链。
- **结论 (C)**：附有理由的最终答案。

这种分解通过提示工程（prompt engineering）来强制执行，并服务于两个目的：(1) 将智能体输出结构化为可解析的组件，从而在所有通信拓扑中实现可靠的结论提取和一致的立场识别——这是其主要经验价值（第 7 节）；(2) 它提供了可分离的组件，借此计算质量信号，充当斯塔克尔伯格机制设计的形式化接口（第 4 节），尽管实验表明，当智能体共享同一底层大语言模型（LLM backend）时，这些信号的判别能力有限（第 7 节）。

3.2 四维质量信号

根据每个智能体的 AEIC 输出，我们利用基于嵌入相似性的方法计算四个质量信号：

Definition 1 (质量信号). 令 $\mathrm{sim}(\cdot,\cdot)$ 表示句子嵌入空间中的余弦相似度。对于智能体 i:

$$\mathrm{IC}_i = \mathrm{sim}(I_i, C_i) \tag{1}$$

$$\mathrm{EC}_i = \frac{1}{|E_i|}\sum_{e\in E_i}\mathrm{sim}(e, C_i) \tag{2}$$

$$\mathrm{EQ}_i = f_{\mathrm{quality}}(E_i) \tag{3}$$

$$\mathrm{EV}_i = \frac{1}{|\mathcal{N}_i|}\sum_{j\in\mathcal{N}_i}\mathrm{sim}(E_i, E_j) \tag{4}$$

其中，*IC* 衡量推理与结论（*Inference–Conclusion*）的一致性，*EC* 衡量证据与结论（*Evidence–Conclusion*）的支撑力度，*EQ* 评估证据质量，*EV* 捕捉跨智能体的证据共识。

此处 $\mathcal{N}_i$ 表示通信拓扑图中智能体 i 的邻居，而 f_{quality} 评估证据覆盖率和具体程度。按照设计，IC、EC 和 EQ 衡量的是个体推理一致性：智能体的分析在内部一致、支持度充分且周密的程度。EV 衡量的是跨智能体共识：某个智能体的证据与其邻居的一致性程度。这种区别对激励设计而言很重要——因为通过阿谀奉承行为可以夸大 EV 的数值。但是，正如我们的实验所展示的（第 7 节），当智能体共享同一底层大语言模型时，这些衡量连贯性的信号无法区分正确和错误的推理：连贯的错误答案与正确答案的得分一样高。

3.3 智能体类型空间

借鉴 Saig 等人的做法 [20]，我们通过一种可观察的类型对每个智能体进行建模：

Definition 2 (智能体类型). 针对问题 q，智能体 i 的类型为：

$$\tau_i = (IC_i, EC_i, EQ_i) \in [0,1]^3 \tag{5}$$

EV 刻意从类型中剔除了。它衡量的是共识而非推理质量——一个有阿谀倾向的智能体可以通过无实际推理地模仿邻居来获得较高的 EV。该类型捕获的是该机制设计上意图去奖励的东西：个人推理的努力程度。在实践中，第 7 节表明，当所有智能体都共享同一个大语言模型后端时，这些类型信号的鉴别能力非常有限。

3.4 AEIC 作为特征提取

除了机制设计外，以 AEIC 为结构的输出还为拓扑路由特征提供了基础。针对每一个问题-拓扑对，我们利用每个智能体的质量信号、摘要统计数据、投票特征（从结论组件中提取多数比例，以及赞成/反对分布）和交叉信号相互作用来构建一个 42 维的特征向量。特征剥离（第 7 节）表明，由于能够从 AEIC 结构中可靠地提取结论而实现的投票特征，是促成较高路由准确率的主要驱动因素，而质量信号仅起到了微弱甚至负面的作用。

4 Stackelberg 共识博弈

4.1 博弈公式化

我们将多智能体共识公式化为一个 Stackelberg 博弈 $\mathcal{G} = (\mathcal{L}, \mathcal{F}, \Theta, \mathcal{S}, U_L, U_F)$。

参与者。 领导者（leader）$\mathcal{L}$ 是机制设计者（双层优化器）。追随者（followers）$\mathcal{F} = \{1, \ldots, n\}$ 是大语言模型（LLM）智能体。

策略空间。 领导者选择机制参数 $\theta \in \Theta \subset \mathbb{R}^{21}$，控制 AEIC 质量信号如何映射到共识权重，以及如何调节集体行为动态。每个追随者 i 选择一个策略 $s_i \in \{s^{\text{ind}}, s^{\text{syc}}\}$：

- s^{ind}（独立推理）：以成本 C_{ind} 产生高 IC、EC、EQ；
- s^{syc}（阿谀奉承）：产生较低的 IC/EC，但可能以较低的成本 $C_{\text{syc}} < C_{\text{ind}}$ 获得高 EV。

时间线。

1. 领导者承诺参数 θ（机制规则）。
2. 每个追随者观察到 θ 并选择策略 s_i。
3. 智能体生成 AEIC 输出；计算质量信号 τ_i。
4. 机制通过评分规则计算权重 $w_i(\tau_i; \theta)$。
5. 加权投票产生共识决策。

效用函数。 追随者的效用为：

$$U_i(s_i; \theta) = w_i(\tau_i(s_i); \theta) \cdot R - C(s_i) \tag{6}$$

其中 $R > 0$ 是被采纳的奖励。领导者最大化：

$$\max_{\theta \in \Theta} \ \text{Accuracy}(\theta) + \lambda \cdot \text{IC}(\theta) \tag{7}$$

4.2 评分规则

21 个参数 θ 控制三个方面：

- **出价构建**（13 个参数）：IC、EC、EQ、EV 信号如何组合成智能体“出价”（对齐意愿 α_i、修正成本、历史对齐度 h_i）。
- **Stackelberg 动态**（4 个参数）：共识能量系数 λ_c、预算惩罚 μ、学习率 η 和同伴压力 γ。
- **动态调节**（4 个参数）：阿谀奉承检测阈值 τ_h、僵局阈值 τ_l、EV 衰减率 α 和压力调整率 β（见第 4.6 节）。

具体而言，对于智能体 i：

$$\alpha_i = \max\big(\theta_{\text{floor}},\ \text{IC}_i^{\theta_{\text{ic}}} \cdot \text{EQ}_i^{\theta_{\text{eq}}} \cdot (\theta_{\text{ev_base}} + \theta_{\text{ev_scale}} \cdot \text{EV}_i)\big) \tag{8}$$

$$h_i = \theta_{h_1} \cdot \text{IC}_i + \theta_{h_2} \cdot \text{EC}_i + \theta_{h_3} \cdot \text{EQ}_i + \theta_{h_4} \cdot \text{EV}_i \tag{9}$$

这些出价通过一个分布式共识博弈进行处理，该博弈通过由通信拓扑定义的图拉普拉斯矩阵引入同伴压力，并经过迭代更新后产生最终权重 $w_i(\theta)$。

4.3 激励兼容性指标

我们通过组间权重比较来定义激励兼容性：

Definition 3 (激励兼容性指标). *对于每个问题 q，按质量得分 $\phi(\tau_i) = (IC_i + EC_i + EQ_i)/3$ 对智能体进行排序。设 H_q 为排名前 2 的智能体，L_q 为排名后 2 的智能体。定义：*

$$IC(\theta) = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{1}\left[\frac{1}{|H_q|} \sum_{i \in H_q} w_i(\theta) > \frac{1}{|L_q|} \sum_{j \in L_q} w_j(\theta) \right] \tag{10}$$

该指标衡量了较高质量的推理获得更高共识权重的问题比例，捕捉了激励兼容性的本质。

4.4 双层优化

Stackelberg 博弈通过双层优化求解：

$$\textbf{上层 (领导者):} \quad \max_{\theta \in \Theta} \ \text{Accuracy}(\theta) + \lambda \cdot \text{IC}(\theta) \tag{11}$$

$$\textbf{下层 (追随者):} \quad w_i = f(\tau_i; \theta) \quad \forall i \tag{12}$$

给定 θ，下层问题是确定性的（智能体的 AEIC 输出是离线固定的），从而简化为单层优化，这可以通过差分进化算法 [21] 来实现。针对每个拓扑优化的 θ_T^* 使用种群大小 21（参数数量的 1 倍）和 30 代进行优化，然后通过 5 折分层交叉验证进行评估，以防止训练/测试数据泄露。我们注意到，Stackelberg 机制提供了形式上的 IC 保证（定理 2），但实验（第 7 节）表明，在同质 LLM 智能体下，质量加权投票的性能并未超越多数投票——瓶颈在于质量信号有限的判别能力，而不是机制设计。

4.5 在线 Stackelberg 扩展

在多轮拓扑（辩论、分层）中，机制*在线*（online）运行：在第 t 轮和第 $t{+}1$ 轮之间，它从第 t 轮的输出计算中间 AEIC 信号，运行 Stackelberg 博弈以获得当前权重 $w_i^{(t)}$，并将质量反馈注入到智能体提示（prompt）中：

$$\text{context}_i^{(t+1)} = \text{context}_i^{(t+1)} \cup \{(\text{IC}_i^{(t)}, \text{EC}_i^{(t)}, w_i^{(t)})\} \tag{13}$$

这将博弈从事后重加权转变为实时行为塑造：智能体观察到它们当前的质量评估，并可以据此调整推理投入。星形拓扑本质上是在线的——通过 Stackelberg 计算的叶节点信任分数被注入到中心节点的综合上下文中。

结合第 4.4 节的静态优化，这建立了一个两层 Stackelberg 演化机制：静态优化发现要抑制*什么*行为（例如，在信息共享拓扑上对 EV 赋予接近零的权重），而在线反馈传达了每个智能体当前表现*如何*。然而，在线扩展在不考虑集体行为模式的情况下注入相同的质量反馈——它无法区分阿谀奉承的从众行为与富有成效的收敛。第 4.6 节引入了第三层来解决这个限制。

4.6 动态阿谀奉承调节

在线 Stackelberg 反馈（第 4.5 节）在轮次之间注入质量信号，但不论集体行为如何均应用统一的干预。在实践中，多轮协商展现出明显的病态模式：*阿谀奉承式收敛*（智能体迅速放弃独立立场，追随正在形成的多数派）和*僵局*（智能体固执地维持初始立场，而不与对立证据进行交锋）。我们引入了一个动态调节层，用于监控集体立场的动态变化并应用差异化的干预措施。

行为指标。 在第 $t-1$ 轮和第 t 轮之间，我们从智能体的结论 $c_i^{(t)}$（可靠地从 AEIC 的结论字段中提取）计算三个指标：

$$\mathrm{SCR}^{(t)} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}\left[c_i^{(t)} \neq c_i^{(t-1)}\right] \tag{14}$$

$$\mathrm{MR}^{(t)} = \max\left(\frac{|\{i : c_i^{(t)} = \text{yes}\}|}{n},\ \frac{|\{i : c_i^{(t)} = \text{no}\}|}{n}\right) \tag{15}$$

$$\mathrm{CS}^{(t)} = \left|\mathrm{MR}^{(t)} - \mathrm{MR}^{(t-1)}\right| \tag{16}$$

其中，SCR（立场改变率，Stance Change Rate）衡量改变了结论的智能体比例，MR（多数比例，Majority Ratio）衡量主导立场的支配程度，CS（收敛速度，Convergence Speed）捕捉多数派增长的速度。

状态分类。 系统将每次轮间过渡分类为以下三种状态之一：

- **阿谀奉承**（$\mathrm{SCR} \geq \tau_h$）：很大比例的智能体改变了立场，表明潜在的从众行为，即智能体放弃独立推理以追随正在形成的多数派。
- **僵局**（$\mathrm{SCR} \leq \tau_l \wedge \mathrm{MR} < 0.8$）：很少有智能体改变立场，且不存在明显的多数派，表明阵营分明，缺乏富有成效的证据交流。
- **健康**（其他）：立场呈适度演变，出现逐渐收敛或稳定的分歧——不需要干预。

阈值 τ_h、τ_l 以及下文的响应参数 α、β 包含在可学习参数向量 θ 中，将基础的 17 个参数扩展到 21 维。双层优化（第 4.4 节）与基础 Stackelberg 参数一起联合发现最佳检测阈值和响应强度。

自适应响应。 在检测到非健康状态时，机制通过两个渠道做出响应：

1. **参数调整**：对于阿谀奉承状态，证据共识权重发生衰减：$\theta_{\text{ev_scale}} \leftarrow \theta_{\text{ev_scale}} \cdot (1-\alpha)$，从而抑制这种奖励从众的信号。同伴压力和共识能量同样降低：$\gamma \leftarrow \gamma \cdot (1-\beta)$，$\lambda_c \leftarrow \lambda_c \cdot (1-\beta)$。对于僵局，这些参数则被*增加*以鼓励互动。$\alpha \in [0.1, 0.9]$ 和 $\beta \in [0.1, 0.6]$ 均由领导者进行优化。
2. **差异化提示**：下一轮的上下文中附加了特定状态的指令：反阿谀奉承提示强调独立推理而非随波逐流；交流提示鼓励与相反的证据进行辩论；中性提示提供标准的协商指导。

这就完成了三层 Stackelberg 演化机制：*静态*优化发现需要抑制哪些行为（第 4.4 节），*在线*反馈传达个人质量评估（第 4.5 节），*动态*调节实时检

测和纠正集体行为病态。核心见解是 Stackelberg 博弈的价值在于集体行为调节——塑造群体的协商方式——而不是基于质量选择个人贡献。

5 自适应拓扑路由

这项工作的一个关键见解是，没有任何单一的通信拓扑能够在所有问题上占据主导地位。我们将拓扑形式化为一个设计变量，并引入了自适应路由。

5.1 通信拓扑

我们将五种通信拓扑定义为加权邻接矩阵 $W \in \mathbb{R}^{n\times n}$：

- **并行 (Parallel)** ($W = \mathbf{0}$)：所有智能体独立推理，智能体之间没有通信。这是标准的自洽性（self-consistency）设置。
- **顺序 (Sequential)** (W = 路径图)：智能体 i 观察智能体 $1, \ldots, i-1$ 的输出。信息单向流动，模仿智能体链架构。
- **星形 (Star)** (W = 星形图)：一个中心节点智能体聚合所有叶节点智能体的输出，并生成综合结果。叶节点智能体独立推理。
- **辩论 (Debate)** (W = 完全图，多轮)：所有智能体都观察所有其他智能体在上一轮中的结论。重复 3 轮，模拟多智能体辩论。
- **分层 (Hierarchical)** (W = 两级树)：智能体被分成多个子组，首先进行内部协商，然后共享子组结论以进行跨组综合。

拓扑结构 W 既影响信号计算（EV 和一致性信号依赖于邻居集 $\mathcal{N}_i$），也影响智能体行为（在顺序、星形、辩论和分层模式下的上下文感知生成）。

5.2 单拓扑参数优化

对于每种拓扑 $T \in \{$并行, 顺序, 星形, 辩论, 分层$\}$，我们通过基于特定拓扑信号的差分进化算法独立优化 θ_T^*：

$$\theta_T^* = \arg\max_{\theta\in\Theta} \ \text{Accuracy}_T(\theta) + \lambda \cdot \text{IC}_T(\theta) \tag{17}$$

这产生了五种专门的共识配置。优化后的参数揭示了特定拓扑的结构特性（图 3）：星形和辩论拓扑为 EV 学习到了接近于零的权重（$w_{\text{EV}} \approx 0.01$），抑制了阿谀奉承风险最高的跨智能体共识信号。分层和顺序拓扑则学习到了较高的共识压力（$\lambda_c > 4.5$），强制在其链式/树状结构内达成一致。

5.3 神经拓扑路由器

为了为每个问题选择最佳拓扑，我们使用从 AEIC 结构化输出中提取的特征训练了一个神经路由器。

特征设计。 对于每个候选拓扑 T，我们构建了一个 42 维的特征向量，包含每个智能体的质量信号（5 个智能体的 IC、EC、EQ、EV 和一致性）、汇总统计量（均值、标准差、范围）、*投票特征*（多数比例、从 AEIC 结论中提取的"是/否"分布）以及跨信号交互特征（例如，$\mathrm{IC}_i \times (1-\mathrm{agreement}_i)$）。另外还有一个 7 维的问题级特征向量，用于捕捉文本特征和跨拓扑的信号方差。正如第 7 节所示，得益于 AEIC 结构化结论提取的支持，投票特征是路由器准确性的主要驱动因素（引入后提升 +2.1 个百分点），而几个质量信号组的贡献微乎其微甚至为负。

路由器架构。 一个*共享拓扑编码器*（包含 LayerNorm 和 GELU 的两层网络，维度从 42 映射到 96）处理每个拓扑的特征。一个*上下文投影层*总结其他四种拓扑的嵌入表示（48 维）。三个*针对特定数据集的评分头*将拼接后的表示（192 维）映射为标量分数，从而实现针对特定数据集的路由选择。

训练。 我们使用具有自适应边距的焦点排序损失（focal ranking loss）：

$$\mathcal{L} = \sum_{(c,w)} \left(\frac{v}{m}\right)^{\gamma} \cdot v, \quad v = \max(0,\ m - (s_c - s_w)) \tag{18}$$

其中 (c, w) 是（正确，错误）拓扑对，m 是适应难度的边距，$\gamma = 3$ 提供了焦点加权。训练使用 AdamW 优化器，带余弦退火策略，训练 300 个 epoch，并使用 5 折分层交叉验证。

Top-1 选择。 路由器选择每个问题得分最高的拓扑作为共识拓扑。凭借针对特定数据集的专门评分头，该方法在 5 个随机种子上实现了 87.6% ± 0.3% 的准确率（5 折交叉验证），而最佳固定拓扑（星形）的准确率为 83.1%。训练用的正确性标签使用多数投票结果，而不是 Stackelberg 加权决策，以避免受优化的 θ^* 参数污染。

6 理论分析

Theorem 1 (斯塔克尔伯格均衡的存在性). *AEIC-斯塔克尔伯格博弈 $\mathcal{G}$ 存在一个斯塔克尔伯格均衡 (θ^*, s^*)。*

证明. 跟随者的策略空间 $\{s^{\text{ind}}, s^{\text{syc}}\}$ 是有限的，因此对于任何 θ 都存在最优响应。参数空间 Θ 是紧致的（有界的）。领导者的目标函数 $\text{Accuracy}(\theta) + \lambda \cdot \text{IC}(\theta)$ 在 Θ 上是有界的。由魏尔斯特拉斯极值定理可知，该最大值在某个 $\theta^* \in \Theta$ 处取得。结合跟随者的最优响应，这就构成了一个斯塔克尔伯格均衡。

Theorem 2 (ϵ-激励相容性). *对于任意 $\epsilon \in (0,1)$，在公式 (7) 中设置 $\lambda \geq \frac{1}{1-\epsilon}$，可以保证 $IC(\theta^*) \geq \epsilon$。*

证明. 我们首先证明可行性：存在 $\theta_0 \in \Theta$ 使得 $\text{IC}(\theta_0) = 1$（设置较大的 IC/EQ 指数，同伴压力 $\gamma = 0$，使得权重与质量严格单调相关）。

根据 θ^* 的最优性：

$$\text{Acc}(\theta^*) + \lambda \cdot \text{IC}(\theta^*) \geq \text{Acc}(\theta_0) + \lambda \cdot 1 \tag{19}$$

重排并代入 $\text{Acc}(\theta_0) - \text{Acc}(\theta^*) \geq -1$：

$$\text{IC}(\theta^*) \geq 1 - \frac{1}{\lambda} \tag{20}$$

设置 $\lambda \geq \frac{1}{1-\epsilon}$，可得 $\text{IC}(\theta^*) \geq \epsilon$。

Theorem 3 (个体理性与福利). *(a) 在 θ^* 下，当 $R \geq C_{ind}/\min_i w_i$ 时，所有智能体均可获得非负效用。*
(b) 对于足够小的 λ，$Accuracy(\theta^*) \geq Accuracy(\theta_{uniform})$。

证明. (a) 由于 $w_i \in [0,1]$ 且 $C(s_i) \leq C_{\text{ind}}$，选择 $R \geq C_{\text{ind}}/\min_i w_i$ 可以确保 $U_i \geq 0$。

(b) 均匀投票对应于 $\theta_{\text{unif}} \in \Theta$。根据最优性可知：$\text{Acc}(\theta^*) + \lambda \cdot \text{IC}(\theta^*) \geq \text{Acc}(\theta_{\text{unif}}) + \lambda \cdot \text{IC}(\theta_{\text{unif}})$。当 $\lambda \to 0$ 时，直接得出 $\text{Acc}(\theta^*) \geq \text{Acc}(\theta_{\text{unif}})$。

分布式共识的收敛性。 在具有同伴压力 $\gamma > 0$ 和通信拓扑 W 的斯塔克尔伯格动力学下，共识能量 $E(t) = \sum_{(i,j)\in\mathcal{E}} (\theta_i(t) - \theta_j(t))^2$ 满足：

$$E(t) \leq E(0) \cdot \exp\left(-\frac{2\gamma t}{n-1}\right) \tag{21}$$

这保证了指数级收敛到共识状态，其速率由 W 的代数连通度和同伴压力系数 γ 决定。

7 实验

7.1 实验设置

数据集。 我们在三个不同的推理基准上进行了评估：MMLU-Hard（研究生水平知识）、StrategyQA（包含隐式推理的常识问题）和 TruthfulQA（对抗性框架下的事实准确性）。每个数据集提供 300 个问题，共计 900 个问题。

智能体配置。 我们在五种通信拓扑（并行、顺序、星型、辩论、层次）的每一种下，部署了 $n = 5$ 个 DeepSeek-V3 [7] 实例，生成了 22,500 个符合 AEIC 结构的回复（5 个智能体 × 900 个问题 × 5 种拓扑）。由于每个拓扑的问题集是独立采样的，900 个问题中有 633 个在所有五种拓扑中重叠（MMLU-Hard/StrategyQA/TruthfulQA 分别为 161/300/172）。跨拓扑比较（路由器、预言机）使用此交集；每个拓扑内的基线比较使用完整的 300 个问题。

信号计算。 质量信号使用句子嵌入 (paraphrase-multilingual-MiniLM-L12-v2) 进行计算。感知拓扑的邻接矩阵 W 决定了用于计算 EV（认知方差）和一致性的邻居集。

优化。 针对特定拓扑的 θ_T^* 通过差分进化算法（21 个参数，种群大小 21，30 代）进行优化，并使用 5 折分层交叉验证进行评估，以报告真实存在的留出集准确率（防止训练/测试数据泄漏）。路由器的评估也使用 5 折交叉验证，并设置五个随机种子以进行稳定性评估。

基线方法。

- **单智能体 (Single Agent)**：不进行聚合，仅使用智能体 0 的结论。
- **ChatEval** [3]：在并行拓扑上进行多数投票（我们的重新实现）。
- **多轮辩论 (Multi-round Debate)** [8]：在 3 轮辩论后进行多数投票（我们的重新实现）。
- **AgentVerse** [5]：求解器–审查器模式，带有中心决策（我们的重新实现，每个数据集 200 个问题）。
- **多数投票 (MajVote)**：在每种拓扑上进行简单的多数投票（5 种变体）。
- **加权投票 (Weighted Vote)**：无斯塔克尔伯格机制的 IC 加权和一致性加权投票。

表 2. 三个数据集的共识准确率 (%)。单拓扑基线各使用 300 个问题；路由器和预言机在所有拓扑共有的 633 个问题上进行评估（MMLU-Hard/StrategyQA/TruthfulQA 分别为 161/300/172）。最佳固定拓扑用斜体表示，整体最佳用**粗体**表示。

方法	MMLU-Hard	StrategyQA	TruthfulQA	平均
单智能体与投票基线				
单智能体 (N=1)	65.3	79.0	80.0	74.8
MajVote (并行)†	69.7	81.7	81.3	77.6
MajVote (顺序)	79.0	71.0	72.7	74.2
MajVote (星型)	*85.7*	*80.3*	*82.0*	*82.7*
MajVote (辩论)†	83.7	72.3	75.3	77.1
MajVote (层次)	82.0	74.7	75.0	77.2
AgentVerse†	74.0	63.5	70.0	69.2
加权投票 (IC)	70.0	80.3	81.0	77.1
AEIC-斯塔克尔伯格 (特定拓扑 θ^*_T)				
AEIC+SG (并行)	71.7	78.0	78.7	$77.8_{\pm 5.6}$‡
AEIC+SG (顺序)	74.7	69.0	70.0	$75.3_{\pm 2.5}$‡
AEIC+SG (星型)	84.3	79.3	82.0	$81.7_{\pm 3.4}$‡
AEIC+SG (辩论)	80.0	72.3	72.0	$76.3_{\pm 3.0}$‡
AEIC+SG (层次)	84.7	76.3	77.0	$77.3_{\pm 3.5}$‡
自适应路由 (我们的方法，5 折交叉验证)				
神经路由器 (共享)	91.3	86.0	84.3	$86.9_{\pm 0.5}$
神经路由器 (特定数据集)	**92.5**	**86.2**	**85.6**	**87.6**$_{\pm 0.3}$
预言机 (5 种拓扑之一)	97.5	91.0	91.9	92.9

† 我们使用 DeepSeek-V3 的重新实现。‡ 平均列报告了 5 折交叉验证测试准确率 ± 标准差；特定数据集列使用全量数据 θ^*。

– **AEIC+SG**：使用特定拓扑 θ^* 的斯塔克尔伯格加权投票（5 种变体）。

所有基线方法都使用相同的 LLM 后端 (DeepSeek-V3) 和相同的缓存响应，以确保比较的公平性。† = 我们的重新实现。

7.2 主要结果

表 2 展示了完整的比较结果。图 1 提供了直观的总结。

主要观察结果：(1) MajVote (星型) 是表现最好的固定拓扑方法，准确率为 82.7%，即使在交叉验证后也优于所有 AEIC+SG 变体（最好的 AEIC+SG

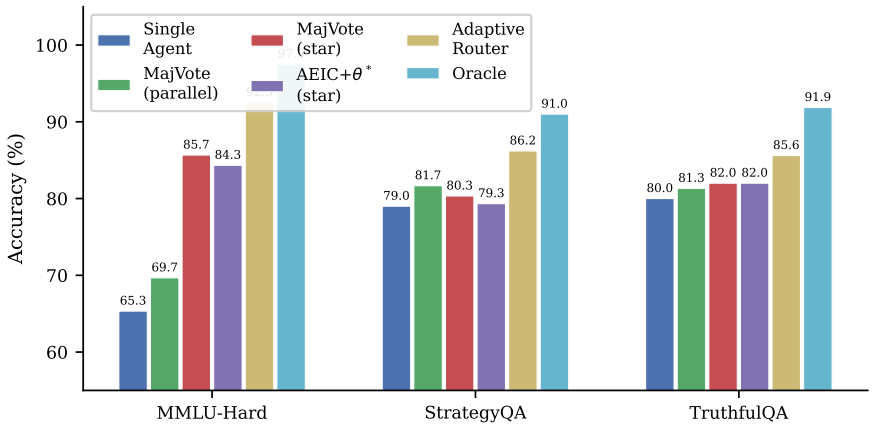


图 1. 三个数据集的准确率比较。自适应路由器优于所有固定拓扑方法。

是星型，为 81.7%)。(2) 自适应路由器达到 87.6%，在对齐的问题上比最佳固定拓扑高出 4.5 个百分点。(3) 预言机上限为 92.9%，还有 5.3 个百分点的提升空间。(4) 按数据集的分析显示，AEIC+SG 在常识推理上落后于 MajVote 最多：在 StrategyQA 上，AEIC+SG 星型的准确率为 79.3%，而 MajVote 星型为 80.3%；而在知识密集型的 MMLU-Hard 上，差距最小（84.3% 对比 85.7%)。(5) AEIC+SG 的交叉验证测试准确率在各拓扑上与 MajVote 紧密匹配（在 5 个拓扑中的 4 个上差距在 1 个百分点以内），这证实了当智能体共享同一个 LLM 后端时，质量加权投票相较于简单多数投票能提供的优势有限。

7.3 AEIC 加权投票与多数投票的对比

图 2 揭示了一个令人惊讶的发现：在 5 种拓扑中的 4 种上，多数投票优于 AEIC+SG 加权投票。

经过诚实的交叉验证评估后，AEIC+SG 与 MajVote 的表现相当：并行 77.8% 对比 77.6%，顺序 75.3% 对比 74.2%，星型 81.7% 对比 82.7%，辩论 76.3% 对比 77.1%，层次 77.3% 对比 77.2%。在全部 900 个问题上（使用在所有数据上训练的特定拓扑 θ^*）进行的 McNemar 检验揭示了混合的结果：AEIC+SG 在并行 (p=0.633)、顺序 (p=0.110) 或星型 (p=0.258) 上并未显著优于 MajVote；在辩论上略差 (p=0.027)；但在层次结构上显著更好 (p=0.001)。层次结构上的显著优势与该拓扑的多级聚合一致，在多级聚合

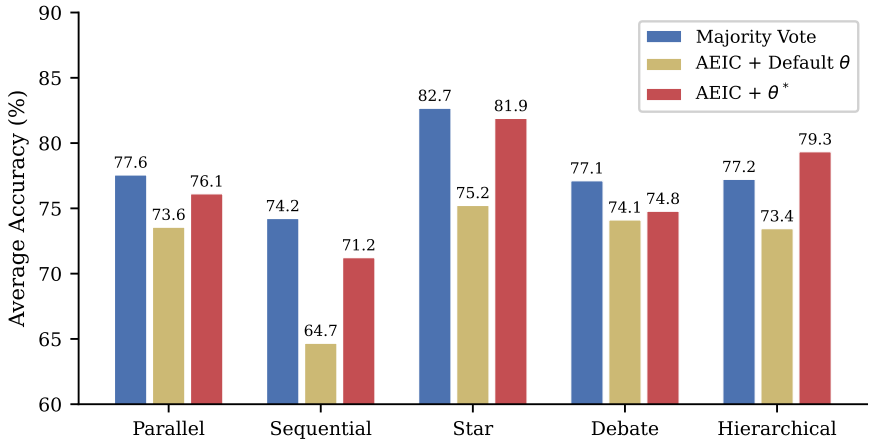


图 2. 三个数据集的各拓扑比较平均值。AEIC+θ^* 仅在层次拓扑上优于多数投票。

中，加权信号提供了增量价值；而在并行、顺序和星型拓扑（智能体要么独立回答，要么共享方向）上缺乏显著差异，证实了当智能体共享同一 LLM 后端时，质量加权投票与简单多数相比没有系统性优势。这证实了 AEIC 质量信号测量的是*推理连贯性，而非答案正确性*：一个连贯的错误答案与正确答案的得分一样高。

结合下面的结构化输出消融实验（第 7.4 节）和特征消融结果，这揭示了 AEIC 的主要价值在于其*结构化分解*：通过强制采用可解析的输出格式，它实现了可靠的结论提取，并在所有五种拓扑中进行一致的多数投票，这反过来又产生了使自适应路由成为可能的投票模式特征。

7.4 结构化输出的价值

为了直接量化 AEIC 结构化格式的贡献，我们比较了从结构化结论 (C) 字段与非结构化推理 (I) 字段中提取立场时的多数投票准确率。C 字段专为提取而设计（例如，“是：[理由]”），而 I 字段包含自由格式的推理链，没有明确的答案标记。

表 3 揭示了巨大的差距：C 字段提取在数据集和拓扑上的平均准确率达到了 76.9%，而 I 字段提取的准确率仅为 48.9%——对于二分类问题来说接近随机。这种差异是由提取可靠性驱动的：I 字段产生不可解析（中立）立场的概率为 66.4%，而 C 字段为 12.7%。当无法提取立场时，多数投票实际上退化为在可解析子集中随机选择。这证实了 AEIC 的主要经验贡献不是质

表 3. 按提取来源划分的多数投票准确率 (%)。C 字段：带有显式答案前缀的结构化结论。I 字段：非结构化推理逻辑链。中立率：无法提取立场的智能体输出的比例。所有五种拓扑的平均值。

数据集	C 字段准确率	I 字段准确率	Δ	C 字段中立率	I 字段中立率
MMLU-Hard	79.8	46.7	+33.1	12.2%	61.3%
StrategyQA	74.5	51.1	+23.4	12.5%	72.6%
TruthfulQA	76.4	48.9	+27.4	13.4%	65.2%
平均	76.9	48.9	+28.0	12.7%	66.4%

量信号，而是结构化格式本身：带有答案前缀格式的显式结论字段实现了可靠的跨拓扑立场提取，这是实现一致的多数投票和驱动自适应路由的投票模式特征的先决条件。

7.5 学习参数分析

图 3 展示了跨五种拓扑优化的 θ^* 参数。

出现了三种模式：(1) **反阿谀奉承**：星型和辩论学习到 $w_{\mathrm{EV}} \approx 0.01$，舍弃了在智能体观察他人输出时的跨智能体共识，使 EV 成为从众心理的替代指标。(2) **链上的高共识压力**：顺序（$\lambda = 4.80$）和层次（$\lambda = 4.69$）强制实行强烈的一致性，以抵消方向性的信息流。(3) **层次拓扑上权重的提升**：所有信号权重都显著较高（0.45–0.90，而其他拓扑为 0.01–0.36），反映了多级聚合中每一个质量维度都有助于识别可靠的中间节点。

7.6 路由器性能演进

图 4 展示了从单智能体到预言机的准确率演进过程。

共享路由器 (86.9%) 在对齐的问题上比最佳固定拓扑 (星型，83.1%) 有了实质性提升。特定数据集的专门化增加了 +0.7 个百分点 (87.6%)，缩小了通往预言机上限 (92.9%) 的 46.5% 差距。所有路由器数据均使用采用 5 折交叉验证的 Top-1 选择。

特定数据集分析。 路由器在各数据集上的优势各不相同：在 MMLU-Hard 上，特定数据集路由器达到 92.5%，而星型拓扑为 90.1%（+2.4 个百分点）；在 StrategyQA 上为 86.2%，而并行拓扑为 81.7%（+4.5 个百分点）；

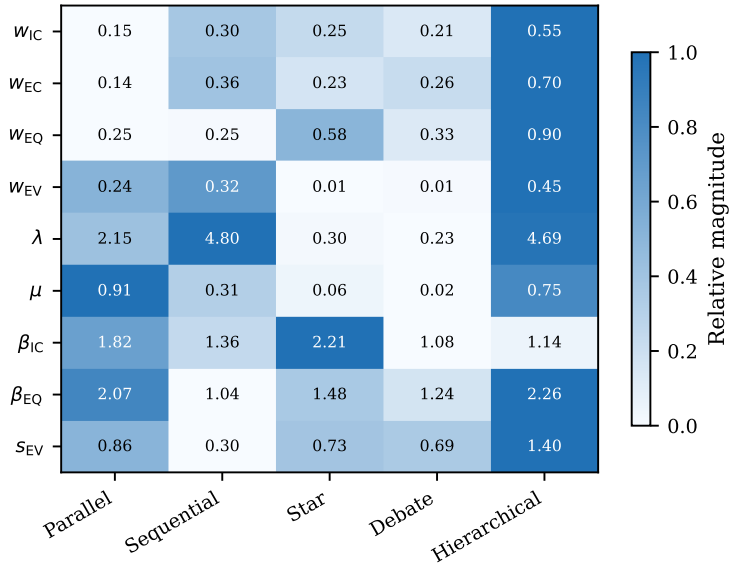


图 3. 五种拓扑优化后的 θ^* 参数（行归一化）。星型和辩论拓扑学习到了接近零的 w_{EV}（反阿谀奉承）。层次拓扑学习到了高 λ 和提高的信号权重。

在 TruthfulQA 上为 85.6%，而星型拓扑为 81.4%（+4.2 个百分点）。在 StrategyQA 上的最大提升反映了常识推理从自适应拓扑选择中获益最多，因为最佳和最差固定拓扑之间的差距最大（81.7% 的并行对比 71.0% 的顺序）。

路由为什么起作用。 图 7 展示了对齐问题上各拓扑准确率的热力图。没有单一拓扑占据主导地位：星型在 MMLU-Hard (90.1%) 和 TruthfulQA (81.4%) 上领先，但并行对于 StrategyQA 最佳 (81.7%)。预言机上限 (∼93%) 要求为不同问题选择不同的拓扑——这正是路由器所学会的。

拓扑一致性。 在 633 个对齐问题中，55.1% 的问题所有五种拓扑都回答正确，7.0% 的问题所有拓扑都回答错误——路由对这 62.1% 的问题没有影响。路由器的价值来自拓扑存在分歧的剩余 37.9%，特别是 9.0% 的“困难”问题，其中只有 1–2 种拓扑成功（图 5）。

路由错误分析。 共享路由器选择每种拓扑的频率大致均衡（16–29%），其中星型拓扑被选择的频率最高（28.6%）。在 83 个路由错误（13.1%）中，有

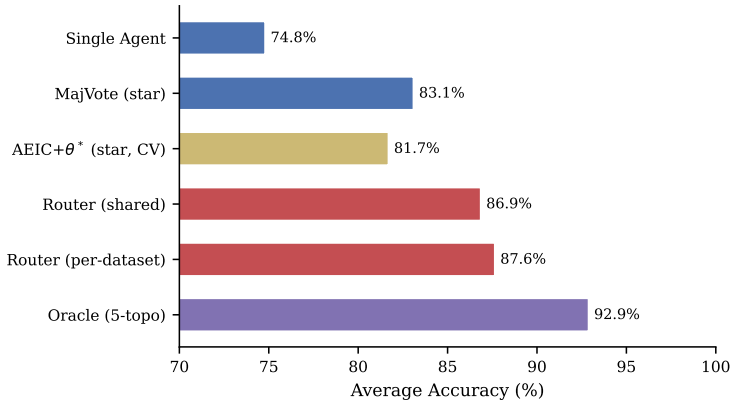


图 4. 从单智能体到预言机的准确率演进过程。特定数据集的路由器缩小了最佳固定拓扑与预言机之间差距的 46.5%。

44 个发生在*没有*任何拓扑产生正确共识的问题上——这是不可避免的失败。只有 39 个错误（6.2%）是真正的路由错误，即存在正确的拓扑但未被选择。

路由器特征重要性。 特征组消融（将每个组置零并测量准确率变化，图 6）表明，**投票特征**（多数比例、是/否分布）对路由最重要（消融时下降 −2.1 个百分点），其次是单智能体的 EV 信号（下降 −0.3 个百分点）。移除与 EQ 相关的特征实际上可以使准确率**提高**多达 1.6 个百分点。为了控制特征相互作用的影响，我们还使用特征子集重新训练了路由器：仅用投票特征达到 86.3%±0.4%，仅用质量特征达到 86.1%±0.3%，而仅用问题特征则为 80.7%±0.0%，相比之下，使用全量特征时为 86.9%±0.5%。投票特征和质量特征各自独立地提供了几乎相同的路由准确率（比仅用问题特征分别高出 +5.6 和 +5.4 个百分点），但将它们结合起来只增加了 +0.6 个百分点，表明存在高度的冗余。这与结构化输出分析（第 7.4 节）一致：投票特征（需要从 AEIC 结构化结论中可靠地提取立场）比试图衡量这一点的质量信号更直接地捕捉到了相同的拓扑-问题交互模式。

7.7 信号消融

图 8 展示了在星型拓扑下每个质量信号对 AEIC+SG 的贡献。

EC 是最关键的信号（−1.15 个百分点）。IC 和 EV 各贡献 ∼0.5 个百分点。移除 EQ 可以将准确率**提高** 0.40 个百分点——这表明证据质量评估在某些领域引入了噪声。

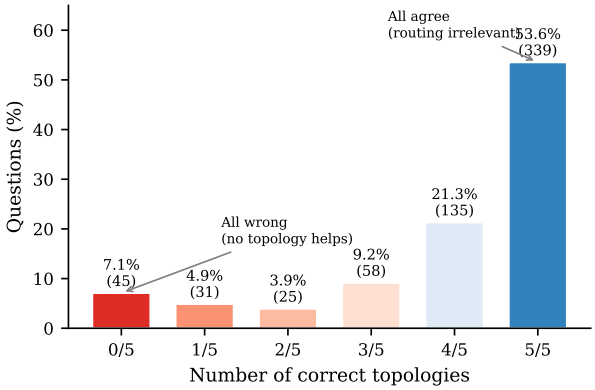


图 5. 每个问题的正确拓扑分布（633 个对齐问题）。路由器的影响集中在拓扑存在分歧的 37.9%（1–4 个正确）上。

表 4. 在线与离线斯塔克尔伯格反馈的对比（MajVote 准确率，%，每个数据集 30 个问题）。在线模式在轮次/阶段之间注入质量信号。

条件	MMLU-Hard	StrategyQA	TruthfulQA	平均
辩论 (离线)	80.0	76.7	83.3	80.0
辩论 (在线)	**86.7**	76.7	76.7	80.0
Δ (在线 − 离线)	+6.7	0.0	−6.7	0.0
层次 (离线)	76.7	80.0	83.3	80.0
层次 (在线)	76.7	73.3	76.7	75.6
Δ (在线 − 离线)	0.0	−6.7	−6.7	−4.4

离线模式使用缓存的响应；在线模式使用动态调用 DeepSeek-V3 API 的结果，带有轮次间质量反馈。

7.8 在线斯塔克尔伯格反馈

我们在辩论和层次拓扑上评估了在线斯塔克尔伯格机制（第 4.5 节），比较了标准执行与注入了轮次间质量信号的在线反馈模式。表 4 显示了每个数据集 30 个问题的结果。

结果揭示了一个微妙的情况：在线反馈在 MMLU-Hard 的辩论拓扑上产生了巨大的提升（+6.7 个百分点），其中迭代辩论结构允许智能体整合质量评估并完善其推理。然而，在其他数据集-拓扑组合中效果不一，在辩论拓扑的总体上没有改善（均为 80.0%），并且在层次拓扑上下降了（−4.4 个百分点）。TruthfulQA 上的性能下降表明，质量反馈可能会加剧对具有对抗性框架问题盲目自信的程度。这些结果促使我们设计了第 4.6 节的动态调节机

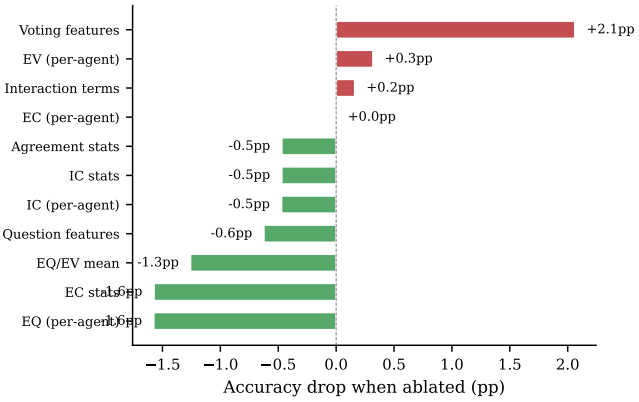


图 6. 通过留一消融法得出的路由器特征组重要性。正值下降表示消融时准确率降低（特征有用）。投票特征最重要；EQ 特征有害。

表 5. 辩论拓扑上的动态阿谀奉承调节（MajVote 准确率，%，每个数据集 n=50）。所有条件均使用匹配问题集的实时 API 调用。

条件	MMLU-Hard	StrategyQA	TruthfulQA	平均
基线 (无反馈)	86.0	78.0	88.0	84.0
静态 (在线)	86.0	74.0	86.0	82.0
动态 (自适应)	**94.0**	74.0	86.0	84.7
Δ (静态 − 基线)	0.0	−4.0	−2.0	−2.0
Δ (动态 − 基线)	**+8.0**	−4.0	−2.0	+0.7
Δ (动态 − 静态)	**+8.0**	0.0	0.0	+2.7

所有条件均在每个数据集上对匹配的 n=50 个问题进行动态调用。

制，该机制基于集体的行为状态来自适应地调整反馈，而不是实行统一的质量暴露。

7.9 动态阿谀奉承调节

我们在辩论拓扑上评估了动态阿谀奉承调节机制（第 4.6 节），每个数据集匹配了 n=50 个问题，比较了三种条件：*基线*（无轮次间反馈）、*静态*（如第 7.8 节所述的统一质量反馈）以及*动态*（具有状态检测和差异化提示的自适应行为调节）。为了保证公平比较，所有条件均在相同的问题集上动态调用 DeepSeek-V3 API。

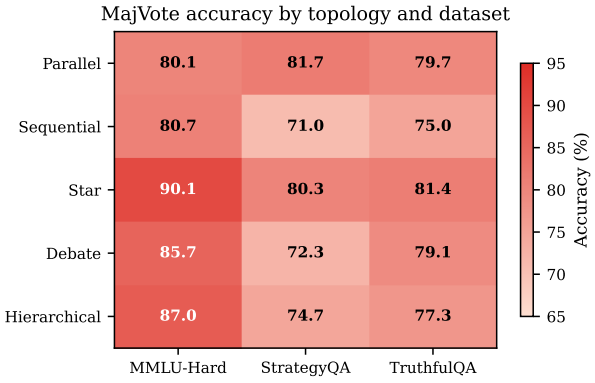


图 7. 对齐问题上各拓扑和数据集的 MajVote 准确率。没有单一拓扑占据主导地位，这解释了自适应路由的动机。

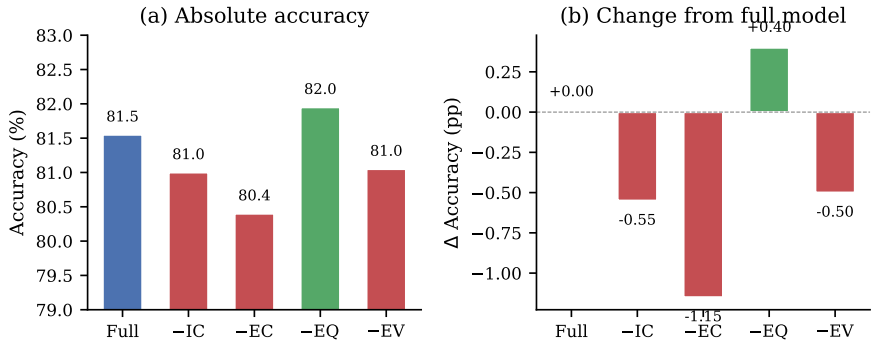


图 8. 星型拓扑下的信号消融。EC 是最关键的信号（−1.15 个百分点）。移除 EQ 略微提高了准确率，这与其较低的优化权重一致。

主要发现是，在 MMLU-Hard 上，动态调节机制带来了比基线和静态反馈显著的改善（+8.0 个百分点），但在 StrategyQA 或 TruthfulQA 上没有提升。MMLU-Hard（具有最复杂、知识密集型推理要求的数据集）的结果证实了该机制的价值：在针对困难数学和科学问题进行多智能体商议时，能检测并抵消阿谀奉承式的趋同。Bootstrap 分析在 n=50 时的 95% 置信区间为 $[-4, +20]$ 个百分点，表明存在需要大规模验证的边缘显著性。

在 StrategyQA 和 TruthfulQA 上，动态调节相较于基线既没有帮助也没有损害，而静态反馈一致导致性能下降 2-4 个百分点。这表明，仅仅在轮次间暴露质量评估（静态）会在常识和事实问题上引入智能体难以解释的噪声，而动态调节的干预性选择则避免了这一陷阱。

分析 256 次轮次间转换的动态行为（50 个问题 × 约 3 个轮次 × 2 次转换）：75.4% 被分类为*健康*（无干预），7.8% 为*阿谀奉承*（反阿谀奉承提示并抑制 EV），16.8% 为*死锁*（鼓励交流）。阿谀奉承状态罕见但影响重大：SCR ≥ 0.6 的转换与仅 55.0% 的问题级准确率相关，而 SCR < 0.2 时准确率为 88.9%，证实了高立场转变率与错误的共识相关。死锁转换更为常见，且中等程度地与较低准确率相关（有干预时为 74.4%，而健康状态为 87.6%）。

利用记录的动态数据对检测阈值（第 4.6 节）进行的网格搜索表明，$\tau_h = 0.45, \tau_l = 0.05$ 能够最大化被干预转换和未被干预转换之间的准确率差异，这说明当前阈值（$\tau_h = 0.6, \tau_l = 0.2$）是相对保守的。未来基于所有 21 个参数（第 4.4 节）的双层优化有望发现更有效的配置，尤其是在特定任务的阈值调整上。

7.10 准确率-激励权衡

优化后的 θ^* 配置无需显式的 IC 约束就能自然地实现高激励相容性：IC 率分别为并行（98.9%）、顺序（94.0%）、星型（98.4%）和辩论（100.0%）。层次拓扑是个例外，仅为 24.2%，这反映出其较高的信号权重优先考虑多级聚合而非严格的质量排序。这表明仅优化准确率就能产生接近 IC 的机制——斯塔克尔伯格权重结构本身就在奖励高质量的推理。λ 项（定理 2）为对抗环境提供了正式保证，但在智能体共享相同 LLM 后端时，其作用基本是冗余的。

8 Discussion

为什么选择 Stackelberg 而不是 Nash? Yi 等人 [32] 将多智能体辩论建模为同时行动的贝叶斯博弈。我们的 Stackelberg 公式对于机制设计而言更加自然：聚合规则在智能体行动之前就已*承诺*（*committed to*），这使得领导者能够通过可信的承诺来塑造追随者的行为——这种属性在所有参与者同时行动的纳什均衡中是不存在的。

质量信号与正确性。 我们最重要的发现是，AEIC 质量信号衡量的是推理过程的质量，而不是答案的正确性。McNemar 检验表明，AEIC+SG 加权投票在三种拓扑结构上与多数投票没有显著差异（并行 p=0.633，顺序 p=0.110，星型 p=0.258），在辩论拓扑上略差（p=0.027），且仅在层级拓扑上显著更

好（p=0.001）。一个连贯、论据充分的错误答案与正确答案得分一样高。这意味着，当智能体共享相同的 LLM 后端和相似的知识偏差时，基于质量的加权不能替代基于多样性的聚合。

对这一局限性的直接测试使用了一个记忆多样化的辩论场景，其中 5 个智能体中有 3 个收到正确的背景知识，另外 2 个收到误导性知识。在这种受控的知识不平衡下，Stackelberg 机制赋予正确记忆智能体（μ_θ=0.509）和被误导智能体（μ_θ=0.499，p=0.889）几乎相等的权重，尽管后者得出了客观上错误的答案。多数投票自然地以 3:2 胜过 2 个被误导的智能体，达到了 93.3% 的准确率，而质量加权共识的准确率为 86.7%。这证实了质量信号无法识别哪些智能体拥有可靠的知识——它们衡量的是推理的内部连贯性，而不是其与事实基础的对应关系。这一发现与跨智能体 NLI 校准结果（AUC = 0.78，与简单的立场匹配相同）以及表明投票模式特征在路由方面优于质量信号的特征消融实验相一致。

提高信号保真度。 用于 IC 和 EC 的基于嵌入的相似度（MiniLM）衡量的是主题相关性，而不是逻辑蕴含——关于主题 X 的连贯错误答案与关于同一主题的正确答案在语义上是接近的。将余弦相似度替换为自然语言推理（NLI）模型（如 DeBERTa-v3 NLI）可能会通过区分逻辑支持和纯粹的语义重叠来提高信号保真度。在 50 个 MMLU-Hard 问题上使用多语言 NLI 模型（mDeBERTa-v3-xnli）的初步实验揭示了这一挑战：自一致性 NLI（I_i 是否蕴含 C_i?）在预测智能体正确性方面的 AUC 仅为 0.55，略高于余弦相似度（AUC = 0.47）。更强的信号来自于跨智能体 NLI 校准——检查每个智能体的推理是否蕴含多数派结论（AUC = 0.78）——但这退化为了多数派一致性（简单立场匹配的 AUC = 0.78），没有提供增量信息。根本的限制在于，当智能体共享相同的 LLM 并且无论正确与否都产生类似连贯的输出时，**自一致性无法区分正确和错误的推理**。同样地，EV 目前通过余弦相似度衡量证据共识，当智能体共享相同的 LLM 后端时，这变成了一个信息回音室指标。打破这一障碍可能需要异构的智能体池，其中多样化的知识库会产生有意义的质量差异。值得注意的是，路由器的成功（87.6%）并不源于质量信号在元级别上克服了这一局限：特征消融表明，投票模式特征——从 AEIC 结构化结论中提取的多数派比例和是/否分布——驱动了路由准确率（+2.1pp），而质量信号组的贡献微乎其微甚至为负。结构化分解本身，而不是质量测量，才是实现有效路由的原因。

AEIC 作为结构化推理协议。 结构化输出消融实验（表 3）为 AEIC 的价值提供了最直接的证据：显式结论（Conclusion）字段的多数投票达到了 76.9% 的准确率，而来自非结构化推理（Inference）字段的准确率为 48.9%（+28.0pp），这是由于 C 字段的低中立率（12.7%）对比 I 字段的 66.4%。路由器特征消融进一步证实了这一点：仅使用投票特征重新训练可达到 86.3%（而全部特征为 86.9%），而仅使用质量特征为 86.1%——这两个特征组在很大程度上是冗余的，并且它们各自独立地比仅使用问题特征（80.7%）提供了约 5.5pp 的提升。因此，在同构智能体系统中，AEIC 的恰当定位是一个*结构化推理协议*（它标准化输出格式以实现可靠聚合，并支持驱动自适应路由的投票模式特征），而不是一个质量测量框架。

基于第一性原理的反阿谀奉承。 最优机制在星型和辩论拓扑上学习到接近零的 EV 权重，提供了一种原则性的反阿谀奉承机制。在信息共享拓扑上，高 EV 反映的是社会影响，而不是独立验证。这是在没有显式约束的情况下通过准确率优化涌现出来的，为启发式方法 [18] 补充了博弈论基础。

预言机差距分析。 路由（87.6%）和预言机（92.9%）之间 5.3pp 的差距源于没有任何拓扑产生正确共识的问题（7.0%），以及尽管存在正确替代方案但所选拓扑失败的路由错误。分析拓扑一致性：在 62.1% 的问题上，所有五种拓扑达成一致（55.1% 全部正确，7.0% 全部错误）；在这里，路由没有提供附加价值。路由器的影响来自于 9.0% 的“困难”问题，其中只有 1–2 种拓扑成功。我们的路由器缩小了最佳固定拓扑（83.1%）与预言机之间 46.5% 的差距。剩余的差距可以通过更丰富的拓扑空间、异构智能体池，或能更好地区分问题难度模式的改进路由特征来缩小。

与基于 RL 的自适应拓扑的比较。 RUMAD [25] 使用强化学习来自适应地控制单一拓扑类型内的辩论轮次和智能体参与。我们的方法在三个方面有所不同：（1）我们在五种根本不同的通信结构（并行、顺序、星型、辩论、层级）中进行选择，而不仅仅是辩论的变体；（2）我们的路由使用从 AEIC 结构化输出中提取的、具有博弈论基础的可解释投票模式特征，而 RUMAD 使用不透明的 RL 策略；（3）我们的 Stackelberg 机制提供了正式的激励相容保证（定理 2）。这两种方法是互补的——可以将拓扑内自适应（RUMAD）和跨拓扑选择（我们的方法）结合起来。

在线 Stackelberg 博弈。我们的在线扩展在轮次之间注入质量反馈，将 Stackelberg 从事后重加权转变为实时激励塑造。实验结果（表 4）表明，其有效性严重依赖于拓扑与任务的交互：辩论在知识密集型任务上获益（n=30 时 MMLU-Hard 提升 +6.7pp），而层级拓扑没有显示出改善（−4.4pp）。好坏参半的结果——尤其是在 TruthfulQA 和层级拓扑上的性能下降——直接促使了动态调节机制的提出。

从质量选择到行为调节。 三层 Stackelberg 演化揭示了该机制所学习控制内容的进展。*静态*优化发现了*哪些*行为应该被抑制——EV 权重在辩论和星型拓扑上收敛到接近零，在没有显式约束的情况下提供了原则性的反阿谀奉承。*在线*反馈传达了*每个智能体的表现*——在轮次之间注入质量评估，以便智能体能够自我纠正。*动态*调节检测*群体在做什么*——监控立场变化率和多数派比例，以区分富有成效的收敛与阿谀奉承的羊群效应或僵局，然后应用针对性的干预。这种演变反映了从个体质量选择（当智能体共享相同的 LLM 并产生类似的连贯输出时会失效）到集体行为调节（对可观察的群体动态进行操作，无论个体信号质量如何）的转变。在 n=50 时，动态调节在 MMLU-Hard 上比基线实现了 +8pp 的提升（94.0% 对比 86.0%，表 5），这种效果集中在需要真正迭代审议的知识密集型问题上。在 StrategyQA 和 TruthfulQA 上，动态调节保持了基线准确率（尽管静态反馈导致性能下降），这证实了选择性干预避免了统一质量暴露带来的噪声。对检测阈值的网格搜索分析进一步表明，当前的设置（τ_h=0.6，τ_l=0.2）是保守的：τ_h=0.45，τ_l=0.05 会在受干预和未受干预的转换之间产生更强的准确率分离，这表明对所有 21 个参数（包括检测阈值）进行联合双层优化，可以通过特定任务的调优释放进一步的收益。值得注意的是，每个数据集的网格搜索揭示了最优阈值在不同任务类型之间存在差异：鉴于 SCR 与正确性之间的强分离（正确的 SCR 平均为 0.19，错误的为 0.30），MMLU-Hard 受益于激进的检测（τ_h=0.35），而 StrategyQA 在 τ_h=0.45 时实现了病态和健康状态的清晰分离（阿谀奉承准确率为 36% 对比健康的 80%），TruthfulQA 则显示出较弱的 SCR 区分度（正确 0.24 对比错误 0.26），这解释了为什么动态调节在事实类任务上几乎没有增加收益。这种最优阈值的任务依赖性反映了一个更广泛的发现，即 Stackelberg 机制受益于每个拓扑的优化（第 7 节）。对 MMLU-Hard 的更细粒度分析表明，僵局干预虽然总体上有价值，但有时会在困难问题上产生适得其反的效果，在这些问题上，正确的少数派立场需要延长的审议时间来说服其他人，而不是被强制交换——受动态调节负面影响

的问题平均有 1.3 次干预，而受正面影响的问题只有 1.0 次。与基于 RL 的自适应方法 [25] 不同，我们的动态调节是完全可解释的——三个指标、三个状态和两个干预通道——并且不需要额外的训练，使得这种故障模式的诊断变得简单明了。

收敛动态与干预通道。 逐轮的多数派比例（MR）轨迹揭示了跨数据集的不同收敛模式。在 MMLU-Hard 上，动态调节下的 MR 从 0.76（第 1 轮）上升到 0.82（第 3 轮），这与富有成效的迭代改进相一致。在 StrategyQA 上，MR 从 0.81 下降到 0.75——智能体在不同轮次中一致性降低，表明辩论结构反而降低了对常识问题的共识。MR 轨迹强烈地预测了结果：正确答案在整个过程中保持较高的 MR（0.81→0.83→0.80），而错误答案在第 2 轮表现出典型的下降（MR 0.67），此时群体短暂地向错误答案收敛，随后部分恢复。这种"错误山谷"模式解释了 MMLU-Hard 上 6% 的净动态收益的大部分，其中在第 2 轮转换时及时的反阿谀奉承干预防止了错误的收敛。

对 150 个动态条件下问题中的 63 次干预进行的通道级分析表明，两个干预通道——参数调整和提示模板——总是同时发生：没有任何转换是在没有参数变化的情况下接受提示修改的，反之亦然。与 EV 抑制配对的反阿谀奉承模板在 MMLU-Hard 上达到了 83.3% 的问题级准确率，但在 StrategyQA 上仅为 36.4%，这证实了提示级的干预是任务敏感的。僵局干预（交流鼓励 + 增加同侪压力）在 MMLU-Hard 上达到了 82.4%，而在 StrategyQA 上为 50.0%。这种系统性的差距表明，StrategyQA 的故障模式无法通过当前的干预类型来纠正——常识推理过程可能需要与动态调节表现优异的知识密集型推理根本不同的监管策略。

局限性。 (1) 路由器需要运行所有五种拓扑以进行特征提取（5× 成本）；在线部署需要仅根据问题特征进行拓扑预测。(2) 所有智能体使用相同的 LLM（DeepSeek-V3）；异构智能体池可能会表现出不同的行为。(3) 在线 Stackelberg 反馈显示出好坏参半的结果：对 MMLU-Hard 的辩论有益，但在 TruthfulQA 和层级拓扑上导致性能下降，这表明需要任务自适应的反馈策略。(4) 动态调节评估在每个数据集上使用 n=50；MMLU-Hard 上 +8pp 的提升具有 $[-4, +20]$pp 的 95% bootstrap 置信区间，需要更大规模的验证才能确立坚实的统计显著性。(5) 问题集并未在所有拓扑中完全共享（900 个问题中只有 633 个在所有五种拓扑中重叠），这限制了路由器评估集的规模。

9 Conclusion

我们提出了一种用于多智能体 LLM 共识的自适应博弈论框架，该框架结合了 AEIC 推理分解、带有在线反馈的 Stackelberg 激励机制，以及神经拓扑路由。在 3 个推理基准测试中，使用 5 个智能体对跨所有 5 种通信拓扑评估的 633 个问题，我们的逐数据集路由器达到了 87.6% 的准确率（比对齐问题上最佳的固定拓扑高 +4.5pp），这证明了 AEIC 结构化输出通过可靠的跨拓扑投票模式比较，实现了有效的自适应拓扑选择。

我们的主要发现包括：（1）AEIC 质量信号衡量的是推理连贯性而不是答案正确性——AEIC+SG 在并行、顺序和星型拓扑上与多数投票没有显著差异（McNemar $p>0.10$），在辩论拓扑上略差（$p=0.027$），且仅在层级拓扑上显著更好（$p=0.001$）；一项受控的记忆多样化辩论实验证实，机制赋予正确记忆和被误导智能体的权重相等（$\mu_\theta=0.509$ 对比 0.499，$p=0.889$），多数投票优于质量加权共识（93.3% 对比 86.7%）；结构化输出消融实验证实了 AEIC 的首要价值：从显式结论（Conclusion）字段提取立场比从非结构化推理文本达到了高出 +28.0pp 的多数投票准确率（76.9% 对比 48.9%），并且结构化格式能够实现可靠的跨拓扑共识；（2）逐拓扑的 Stackelberg 优化发现了可解释的参数配置文件，包括反阿谀奉承效应（在信息共享拓扑上，跨智能体共识信号被抑制）；（3）该机制自然地实现了高激励相容性（在 5 种拓扑中有 4 种达到 94–100%），而无需显式的 IC 约束；以及（4）Stackelberg 机制通过三个层次演进：静态优化发现了反阿谀奉承原则，在线反馈提高了知识密集型任务上的辩论准确率（$n=30$ 时 MMLU-Hard 提升 +6.7pp），而动态阿谀奉承调节——监控集体立场动态（分析了 256 次转换）并应用自适应干预——在知识密集型推理上取得了最佳准确率（MMLU-Hard 为 94.0%，在 $n=50$ 时比基线和静态方法都高 +8pp），同时在其他任务上保持了基线准确率（在这些任务上，统一的静态反馈会降低准确率），这证明了选择性行为调节优于统一基于质量的加权的价值。

未来的工作包括：用基于 NLI 的蕴含评分替代嵌入相似度——我们的初步实验表明，跨智能体 NLI 校准与异构智能体池相结合可能会克服本研究中确定的自一致性上限；开发在线路由，仅凭问题特征来选择拓扑，而无需运行所有候选拓扑；探索具有多样化 LLM 后端的异构智能体池，其中质量信号可能变得更具区分度；通过更大规模的验证细化动态调节阈值；以及将跨拓扑选择与拓扑内自适应相结合 [25]。

Disclosure of Interests. The authors have no competing interests to declare.

参考文献

1. Anand, S., Xu, W., Tang, M., Ramesh, A., Li, Y.: Resilient consensus in agentic AI. arXiv preprint arXiv:2606.15024 (2026)
2. Bertalanič, B., Fortuna, C.: The cost of consensus: Isolated self-correction prevails over unguided homogeneous multi-agent debate. CoRR **abs/2605.00914** (2026). https://doi.org/10.1145/3786335.3813137, https://arxiv.org/abs/2605.00914
3. Chan, C.M., Chen, W., Su, Y., Yu, J., Xue, W., Zhang, S., Fu, J., Liu, Z.: ChatEval: Towards better LLM-based evaluators through multi-agent debate. In: Proceedings of the 12th International Conference on Learning Representations (ICLR) (2024), https://arxiv.org/abs/2308.07201
4. Chen, J.C.Y., Saha, S., Bansal, M.: ReConcile: Round-table conference improves reasoning via consensus among diverse LLMs. In: Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL). pp. 3539–3561 (2024). https://doi.org/10.18653/v1/2024.acl-long.193, https://arxiv.org/abs/2309.13007
5. Chen, W., Su, Y., Zuo, J., Yang, C., Yuan, C., Chan, C.M., Yu, H., Lu, Y., Hung, Y.H., Qian, C., Qin, Y., Cong, X., Xie, R., Liu, Z., Sun, M., Zhou, J.: AgentVerse: Facilitating multi-agent collaboration and exploring emergent behaviors. In: Proceedings of the 12th International Conference on Learning Representations (ICLR) (2024), https://arxiv.org/abs/2308.10848
6. Choi, H.K., Zhu, X., Li, Y.: Debate or vote: Which yields better decisions in multi-agent large language models? CoRR **abs/2508.17536** (2025). https://doi.org/10.48550/arXiv.2508.17536
7. DeepSeek-AI: DeepSeek-V3 technical report. CoRR **abs/2412.19437** (2024). https://doi.org/10.48550/arXiv.2412.19437, https://arxiv.org/abs/2412.19437
8. Du, Y., Li, S., Torralba, A., Tenenbaum, J.B., Mordatch, I.: Improving factuality and reasoning in language models through multiagent debate. In: Proceedings of the 41st International Conference on Machine Learning (ICML) (2024), https://arxiv.org/abs/2305.14325
9. Fu, Y., Dong, M., Zhou, L., Li, C., Yu, F.R.: A distributed incentive mechanism to balance demand and communication overhead for multiple federated learning tasks in IoV. IEEE Internet of Things Journal **11**(4), 5997–6013 (2024)

10. Guo, W., Wang, Y., Jiang, P.: Incentive mechanism design for federated learning with Stackelberg game perspective in the industrial scenario. Computers & Industrial Engineering **186**, 109741 (2023)

11. Han, S., Zhang, Q., Jin, W., Xu, Z.: LLM multi-agent systems: Challenges and open problems. CoRR **abs/2402.03578** (2024). https://doi.org/10.48550/arXiv.2402.03578, https://arxiv.org/abs/2402.03578

12. Hong, S., Zhuge, M., Chen, J., Zheng, X., Cheng, Y., Zhang, C., Wang, J., Wang, Z., Yau, S.K.S., Lin, Z., Zhou, L., Ran, C., Xiao, L., Wu, C., Schmidhuber, J.: MetaGPT: Meta programming for a multi-agent collaborative framework. In: Proceedings of the 12th International Conference on Learning Representations (ICLR) (2024), https://arxiv.org/abs/2308.00352

13. Kumarappan, S., et al.: Not just RLHF: Why alignment alone won't fix multi-agent sycophancy. arXiv preprint arXiv:2605.12991 (2026), https://arxiv.org/abs/2605.12991

14. Li, Y., Zhu, C., Wang, M., Wu, M., Zhu, M., Hu, X.: Dynamic weighted consensus framework for LLM multi-agent debate. In: Lecture Notes in Computer Science. Springer (2025). https://doi.org/10.1007/978-981-95-3001-4_14

15. Liu, J., Guo, M., Conitzer, V.: An interpretable automated mechanism design framework with large language models. CoRR **abs/2502.12203** (2025). https://doi.org/10.48550/arXiv.2502.12203, https://arxiv.org/abs/2502.12203

16. Liu, R., Chen, J., Khanna, A., Zhang, E., Zhao, R., Zhou, A.: The memory curse: How expanded recall erodes cooperative intent in LLM agents. arXiv preprint arXiv:2605.08060 (2026)

17. Meng, Y., Xi, Z., Narvekar, S.S., Vaje, R.R., Zhang, Y., Chen, H.: EquiMem: Calibrating shared memory in multi-agent debate via game-theoretic equilibrium. arXiv preprint arXiv:2605.09278 (2026)

18. Pitre, P., Ramakrishnan, N., Wang, X.: CONSENSAGENT: Towards efficient and effective consensus in multi-agent LLM interactions through sycophancy mitigation. In: Findings of the Association for Computational Linguistics: ACL 2025 (2025). https://doi.org/10.18653/v1/2025.findings-acl.1141

19. Rauba, P., Cepenas, S., van der Schaar, M.: Multi-agent systems should be treated as principal-agent problems. CoRR **abs/2601.23211** (2026). https://doi.org/10.48550/arXiv.2601.23211, https://arxiv.org/abs/2601.23211

20. Saig, E., Einav, O., Talgam-Cohen, I.: Incentivizing quality text generation via statistical contracts. In: Advances in Neural Information Processing Systems 37 (NeurIPS) (2024), https://arxiv.org/abs/2406.11118

21. Storn, R., Price, K.: Differential evolution – a simple and efficient heuristic for global optimization over continuous spaces. Journal of Global Optimization **11**(4), 341–359 (1997). https://doi.org/10.1023/A:1008202821328

22. Sun, H., Wu, Y., Wang, P., Chen, W., Cheng, Y., Deng, X., Chu, X.: Game theory meets large language models: A systematic survey with taxonomy and new frontiers. In: Proceedings of the 34th International Joint Conference on Artificial Intelligence (IJCAI) (2025), https://arxiv.org/abs/2502.09053

23. Swamy, S., et al.: Peacemaker or troublemaker? Sycophancy in multi-agent debate. arXiv preprint (2025)

24. Tran, K.T., Dao, D., Nguyen, M.D., Pham, Q.V., O'Sullivan, B., Nguyen, H.D.: Multi-agent collaboration mechanisms: A survey of LLMs. CoRR **abs/2501.06322** (2025). https://doi.org/10.48550/arXiv.2501.06322, https://arxiv.org/abs/2501.06322

25. Wang, C., Lin, H., Tang, H., Lin, H., Ding, W.: RUMAD: Reinforcement-unifying multi-agent debate. CoRR **abs/2602.23864** (2026). https://doi.org/10.48550/arXiv.2602.23864, https://arxiv.org/abs/2602.23864

26. Wang, X., Wei, J., Schuurmans, D., Le, Q.V., Chi, E.H., Narang, S., Chowdhery, A., Zhou, D.: Self-consistency improves chain of thought reasoning in language models. In: Proceedings of the 11th International Conference on Learning Representations (ICLR) (2023), https://arxiv.org/abs/2203.11171

27. Wang, Y., Zhou, Y., Huang, P.Q.: A novel incentive mechanism for federated learning over wireless communications. IEEE Transactions on Artificial Intelligence **5**(11), 5549–5563 (2024)

28. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E.H., Le, Q.V., Zhou, D.: Chain-of-thought prompting elicits reasoning in large language models. Advances in Neural Information Processing Systems **35** (2022)

29. Xu, S., Wang, Y., Jia, X., Wu, Z., Liu, K., Dong, A.X.: RCBSF: A multi-agent framework for automated contract revision via Stackelberg game. CoRR **abs/2604.10740** (2026). https://doi.org/10.48550/arXiv.2604.10740, https://arxiv.org/abs/2604.10740

30. Yao, S., Yu, D., Zhao, J., Shafran, I., Griffiths, T., Cao, Y., Narasimhan, K.: Tree of thoughts: Deliberate problem solving with large language models. Advances in Neural Information Processing Systems **36** (2024)

31. Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., Cao, Y.: React: Synergizing reasoning and acting in language models. International Conference on Learning Representations (2023)

32. Yi, X., Zhou, Z., Cao, C., Niu, Q., Liu, T., Han, B.: From debate to equilibrium: Belief-driven multi-agent LLM reasoning via Bayesian Nash equilibrium. CoRR **abs/2506.08292** (2025). https://doi.org/10.48550/arXiv.2506.08292, https://arxiv.org/abs/2506.08292

33. Zhao, X., Wang, K., Peng, W.: An electoral approach to diversify LLM-based multi-agent collective decision-making. In: Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP). pp. 2777–2795 (2024). https://doi.org/10.18653/v1/2024.emnlp-main.158